Текст

Лекција 5

Стеван Гостојић

Факултет техничких наука, Нови Сад

31. март 2022.

Преглед садржаја

1. Увод
2. Текст
3. Претрага и индексирање
4. Apache Lucene Core
5. Закључак

Преглед садржаја

1 Увод

2 Текст

3 Претрага и индексирање

4 Apache Lucene Core

5 Закључак

Текст

- Текст је, у општем случају, низ знакова који преносе неку поруку

PRIMER

Danas je lep dan.

1. svaki karakter 1 broj
2. imamo 4 reci i svaka se pojavljuje 1
3. danas je, je lep, lep dan, frekvencija za sve 1

Текст

- Велика количина информација складишти се и преноси у облику текста (тј. текстуалних докумената као јединичних носилаца информација)
- Технике и алати за складиштење и претраживање текста разликују се од техника и алата за складиштење других врста информација
- Познавање ових техника и алата доприноси писању ефикаснијих и ефектнијих рачунарских програма који обрађују текст

Преглед садржаја

1 Увод

2 Текст

3 Претрага и индексирање

4 Apache Lucene Core

5 Закључак

Репрезентација текста

- Посоји више метода за рачунарску репрезентацију текста
- Неке од тих метода су представљање текста као низа знакова, као вектора и као фреквенције н-торки

Низ знакова

- Текст можемо да представимо као низ знакова (који су кодирани одређеним кодом)
- Временом су настали различити кодови за кодирање знакова

Вектор

- Други начин за репрезентацију текста је вектор речи (тј. токена)
- У том случају су димензије вектора речи које се појављују у тексту, а интензитет појединачних компоненти вектора број појављивања одговарајуће речи у документу

Фреквенција н-торки

- Текст можемо да представимо и као фреквенцију појављивања различитих н-торки речи у тексту
- Можемо да посматрамо уређене парове, уређене тројке, уређене четворке итд.

Кодирање знакова

- С обзиром да рачунари податке складиште, преносе и обрађују као низ битова, знаке неког језика је потребно кодирати у неком коду
- Код је пресликавање скупа знакова на скуп бинарних речи
- Постоје многи стандарди за кодирање знакова од којих је данас у најширој употреби Unicode

ASCII

1 znak duzine 7 bita

- American Standard Code for Information Interchange (ASCII) je je стандард за кодирање текста
- Садржи 128 знакова (од којих су неки контролни знаци)
- Основа је модерних стандарда за кодирање текста

ASCII

Знак	Код (децимално)	Код (бинарно)
A	65	100 0001
B	66	100 0010
C	67	100 0011
a	97	110 0001
b	98	110 0010
c	99	110 0011

Table 1: ASCII

ISO/IEC 8859

mana: koristimo 8 bitova da bismo zapisali 1 znak, stoga maks. mozemo da predstavimp 256 znakokva, od kojih su 128 ascii

- ISO/IEC 8859 је фамилија стандарда за кодирање знакова која је заједничкии прописана од ISO и IEC
- То је проширење ASCII стандарда
- ISO/IEC 8859 је подељен у неколико делова који стандардизују кодирање знакова различитих језика (нпр. ISO/IEC 8859-2 садржи српске латиничке знакове, а ISO/IEC 8859-5 српске ћириличне знакове)

Unicode

- Unicode је стандард за конзистентно кодирање, репрезентацију и руковање текстом
- Такође је проширење ASCII стандарда
- Садржи више 144,697 знакова који покривају 159 језика (верзија 14.0 од септембра 2021)
- Знакови се могу кодирати на више начина (UTF-8, UTF-16, UTF-32 итд.)
- Прописује га Јуникод конзорцијум (енг. Unicode Consortium)

Преглед садржаја

1 Увод

2 Текст

3 Претрага и индексирање

4 Apache Lucene Core

5 Закључак

Проналажење

- Проналажење (енг. retrieval) или претрага (енг. search) текста је процес одабира докумената који задовољавају одређени упит
- На пример, претраживање интернета коришћењем Google претраживача

Прегледање

- Прегледање (енг. browsing) текста је процес одабира докумената на основу веза са другим документима
- На пример, праћење хиперлика од једног HTML документа до другог HTML документа

Индексирање текста

- Индексирање текста је процес прављења индекса у циљу убрзавања претраге текста
- Појам индекса потиче из библиотечке делатности
- У зависности од техника које се користе за (рачунарску) претрагу текста, индекси се имплементирају као различите структуре података

Претраживачи

- Претраживачи (енг. search engine) су рачунарски програми чија је основна функција индескирање и претрага текстуалних докумената
- Претраживачи могу да буду понуђени као сервиси или као библиотеке које се уграђују у рачунарске програме

Преглед садржаја

1 Увод

2 Текст

3 Претрага и индексирање

4 Apache Lucene Core

5 Закључак

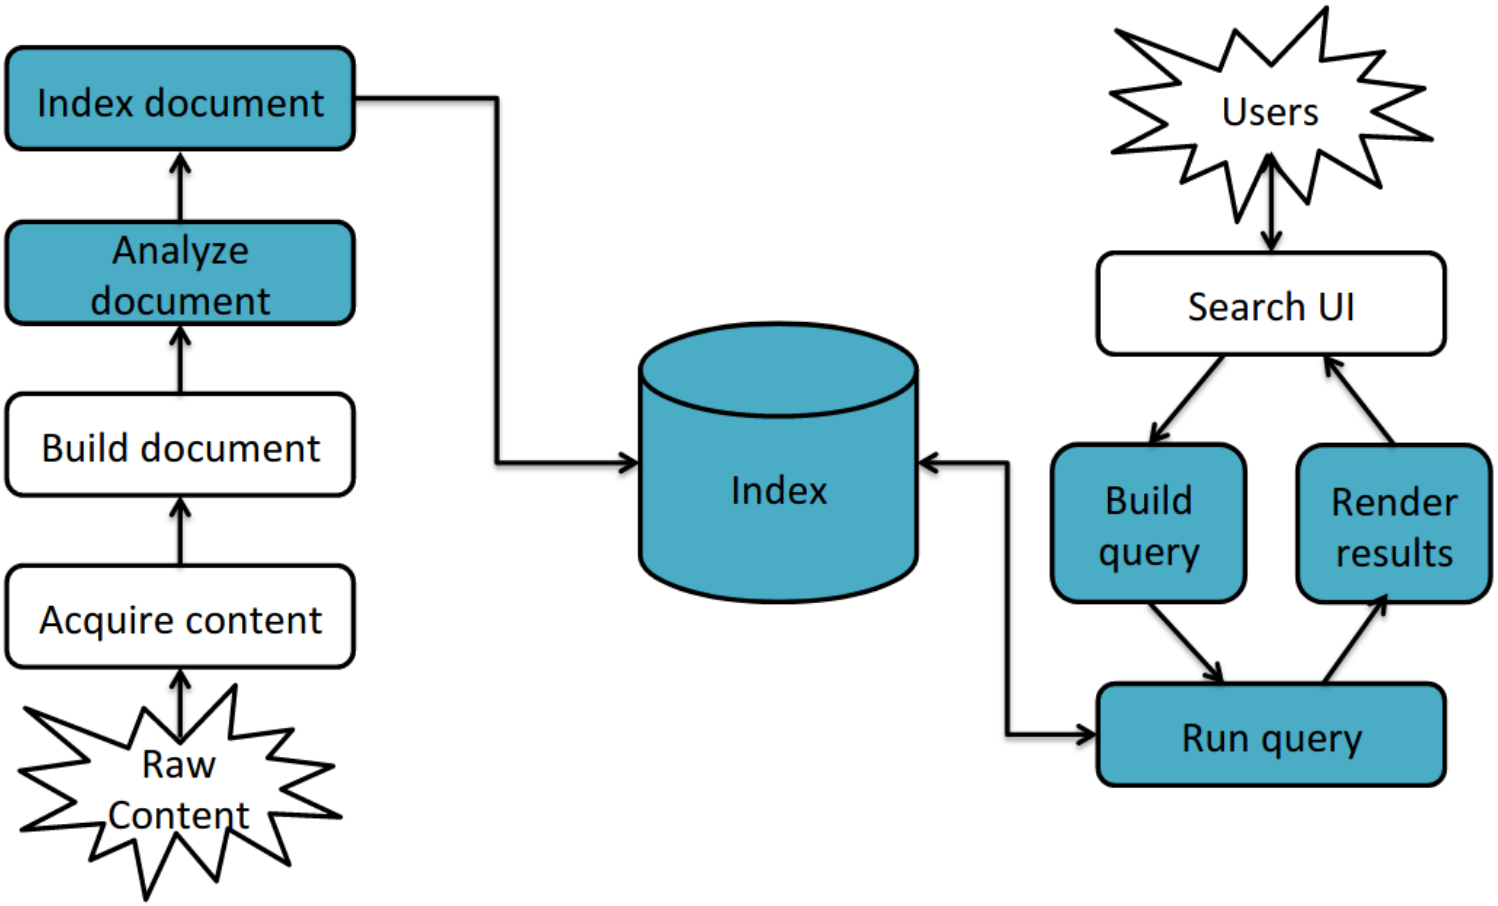
Apache Lucene Core

- Apache Lucene Core је Java API за (индексирање) и претрагу текста
- Постоје конектори и за друге програмске језике и платформе (нпр. Python)
- Apache Lucene Core имплементира напредне методе претраге текста, има високе перформансе и захтева релативно мало ресурса

Apache Lucene Core

- Основна јединица индексирања и претраге су (текстуални) документи
- Документи се састоје од поља (различити типови докумената састоје се од различитих поља) fields!!!!
- Сирови текстуални документи се преводе у једно или више поља (која могу а не морају да се индексирају и анализирају)

Apache Lucene Core



Lucene анализатори

- WhitespaceAnalyzer (дели текст на токене по белим знацима)
- SimpleAnalyzer (дели текст на токене по знацима који нису слова, па их претвара у мала слова)
- StopAnalyzer (исто као и SimpleAnalyzer, али и уклања тзв. "стоп речи")
- StandardAnalyzer (најчешће коришћен анализатор који, за разлику од StopAnalyzer анализатора, нуди и неке "напредне" функције као што је препознавање URL адреса, адреса електронске поште итд.)
- итд.

WhitespaceAnalyzer

```
1 ''The quick brown fox jumped over the lazy dog''
2 [The] [quick] [brown] [fox] [jumped] [over] [the] [lazy] [dog]
3
```

WhitespaceAnalyzer

```
1 ''XY&Z Corporation - xyz@example.com''
2 [XY&Z] [Corporation] [-] [xyz@example.com]''
3
```

SimpleAnalyzer

```
1 ''The quick brown fox jumped over the lazy dog''
2 [the] [quick] [brown] [fox] [jumped] [over] [the] [lazy] [dog]
3
```

SimpleAnalyzer

```
1 ''XY&Z Corporation - xyz@example.com''
2 [xy] [z] [corporation] [xyz] [example] [com]
3
```

StopAnalyzer

```
1 ''The quick brown fox jumped over the lazy dog''
2 [quick] [brown] [fox] [jumped] [over] [lazy] [dog]
3
```

StopAnalyzer

```
1 ''XY&Z Corporation - xyz@example.com''
2 [xy] [z] [corporation] [xyz] [example] [com]
3
```

StandardAnalyzer

```
1 ''The quick brown fox jumped over the lazy dog''
2 [quick] [brown] [fox] [jumped] [over] [lazy] [dog]
3
```

StandardAnalyzer

```
1 ''XY&Z Corporation - xyz@example.com''
2 [xy&z] [corporation] [xyz@example.com]
3
```

Apache Lucene Core

- Колекције текстуалних докумената могу да се претражују на два начина
- Први је Apache Lucene Core API
- Други је Apache Lucene Core Query Parser упитног језика

Query Parser упитни језик

- Синтакса (и семантика) Query Parser упитног језика није стандардизована и може да (незнатно) варира од верзије до верзије Lucene-а
- У примерима је приказан упитни језик за Apache Lucene Core 9.1

Термини

- Термини су појединачни термини или фразе
- Појединачни термини су речи
- Фразе су низ речи под двоструким наводницима

Термини

```
1 Hello
2 "Hello World"
3
```

Поља

- Поља су уређени парови кључ:вредност
- Вредности поља су термини
- Једно поље може да буде подразумевано (тада термини не морају да се квалификују кључем)

Поља

```
1 title:"Hello World"
2 title:Hello World
3 text:go
4 go
5
```

Упити

- Упити се састоје од поља и логичких оператора
- Логички оператори се користе да би се више поља комбиновало у (сложени) упит

Lucene упити

```
1 title:"Hello World" AND text:go
2 title:"Hello World" AND go
3 title:Hello World
4
```

Модификатори

- Модификатори су речи који се користе за модификовање термина (и упита)

Модификатори



- Претраге "џокер" знацима (енг. wildcard searches)
- Претраге регуларним изразима (енг. regular expression searches)
- "Фази" претраге (енг. fuzzy searches)
- Претраге по близини (енг. proximity searches)
- Претраге по интервалима (енг. range searches)
- "Појачавање" термина (енг. boosting a term)
- Логички оператори (енг. boolean operators)
- Груписање (енг. grouping)

Претраге ''џокер'' знацима

- Lucene подржава претрагу ''џокер'' знацима ''?'' и ''*'' над појединачним терминима
- ''Џокер'' знак ''?'' замењује било који знак
- ''Џокер'' знак ''*'' замењује било који низ знакова
- ''Џокер'' знаци ''?'' и ''*'' не могу да се налазе на почетку термина

Претраге ''џокер'' знацима

```
1 te?t
2 test*
3
```

Претраге регуларним изразима

- Lucene подржава претрагу регуларним изразима
- И синтакса (и семантика) регуларних израза може да (незнатно) варира од верзије до верзије Lucene-а
- Регуларни изрази наводе се између знакова "/"

Претраге регуларним изразима

```
1 /[mb]oat/
2
```

Регуларни изрази

- Регуларни изрази су низ знакова који специфицирају текстуални образац

Регуларни изрази

Израз	Опис
\d	цифра
\D	све осим цифре
\s	бели знак
\S	све осим белог знака
\w	слово
\W	све осим слова

Table 2: Регуларни изрази

Регуларни изрази

Израз	Опис
.	било који знак
”текст”	текст
[abcde]	класа знакова
[^abcde]	негација класе знакова
|	унија

Table 3: Регуларни изрази

Регуларни изрази

Израз	Опис
?	нула или једно појављивање
*	нула или више појављивања
+	једно или више појављивања
{n}	n појављивања
{n,}	n или више појављивања
{n,m}	n до m појављивања

Table 4: Регуларни изрази

Претраге регуларним изразима

```
1 [a-z0-9_-]{3,16}
2 #?([a-f0-9]{6}|[a-f0-9]{3})
3 ([a-z0-9_\.-]+)@([\da-z\.-]+)\.([a-z\.]{2,6})
4 (https?:\/\/)?([\da-z\.-]+)\.([a-z\.]{2,6})([\/\w \.-]*)*\/?
5
```

”Фази” претраге

- Lucene подржава ”фази” претраге (тј. претраге по сличним речима)
- Сличност је дефинисана мером Levenshtein Distance (минималним бројем знакова које је потребно променити да би се једна речи трансформисала у другу реч)

''Фази'' претраге

```
1 roam~
2 roam~0.8
3
```

Претраге по близини

- Lucene подржава претрагу докумената у којима се одређене речи налазе на одређеном растојању

Претраге по близини

```
1 "jakarta apache"~10
2
```

Претраге по интервалима

- Lucene подржава претрагу докумената чија поља имају вредности у одређеном интервалу
- Интервали се специфицирају навођењем доње и горње границе и могу да буду отворени (''{'' и ''}'') и затворени (''['' и '']'')

Претраге по интервалима

```
1 mod_date:[20020101 TO 20030101]
2 title:{Aida TO Carmen}
3
```

”Појачавање” термина

- Lucene подржава појачавање релевантности једног термина у односи на друге термине (релевантност термина утиче на рангирање резултата претраге)
- Што је фактор појачавања већи, термин је јелевантнији (фактор појачавања мора да буде позитиван)

”Појачавање” термина

```
1 jakarta apache
2 jakarta^4 apache
3 "jakarta apache"^4 "Apache Lucene"
4
```

Логички оператори

- Lucene подржава комбиновање термина коришћењем логичких оператора
- То су оператори AND, "+", OR, NOT и "-"
- Логички оператор OR се подразумева

Логички оператори

```
1 "jakarta apache" jakarta
2 "jakarta apache" OR jakarta
3 +jakarta lucene
4 "jakarta apache" AND "Apache Lucene"
5 "jakarta apache" NOT "Apache Lucene"
6 "jakarta apache" -"Apache Lucene"
7
```

Груписање

- Lucene подржава груписање израза коришћењем заграда

Груписање

```
1 (jakarta OR apache) AND website
2
```

Преглед садржаја

1 Увод

2 Текст

3 Претрага и индексирање

4 Apache Lucene Core

5 Закључак

Закључак

- Методе репрезентације текста
- Низ знакова
- Вектор
- Фреквенција н-торки
- Кодови
- Unicode

Закључак

- Претрага
- Прегледање
- Индексирање
- Претраживачи

Закључак

- Apache Lucene Core
- Анализатори
- Query Parser упитни језик
- Термини
- Поља
- Упити

Закључак

- Претраге "џокер" знацима
- Претраге регуларним изразима
- "Фази" претраге
- Претраге по близини
- Претраге по интервалима
- "Појачавање" термина
- Логички оператори
- Груписање

Литература

- Apache Lucene Core, https://lucene.apache.org/

Хвала на пажњи!