Soft kompjuting

Projekti prethodnih generacija

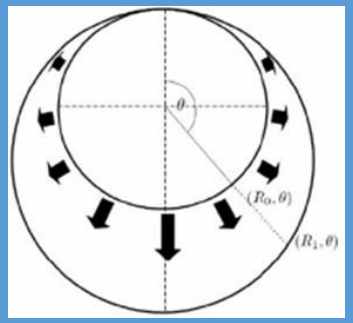
Zadatak: određivanje starosti lica

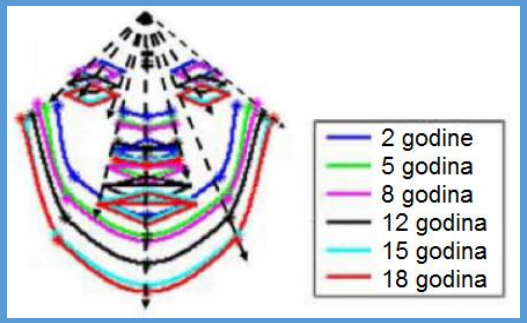
- Pronaći lice na video snimku
- Klasifikovati lice u jednu od tri predefinisane starosne kategorije:
  - Deca
  - Mlađi odrasli
  - Stariji odrasli
- Rad u realnom vremenu

Andrijana Stefanović i Marko Žužić https://github.com/ftn-ai-lab/sc-2016-e2/issues/71

Uticaj starenja

Deca → Mlađi odrasli





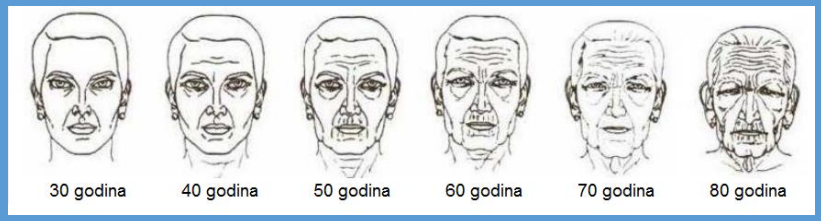
$$F1 = \frac{udaljenost\ između\ unutrašnjih\ uglova\ očiju}{udaljenost\ oka\ i\ vrha\ nosa}$$

$$F2 = \frac{udaljenost\ između\ unutrašnjih\ uglova\ očiju}{udaljenost\ oka\ i\ usne}$$

$$F3 = \frac{udaljenost\ \ oka\ i\ vrha\ nosa}{udaljenost\ oka\ i\ vrha\ brade}$$

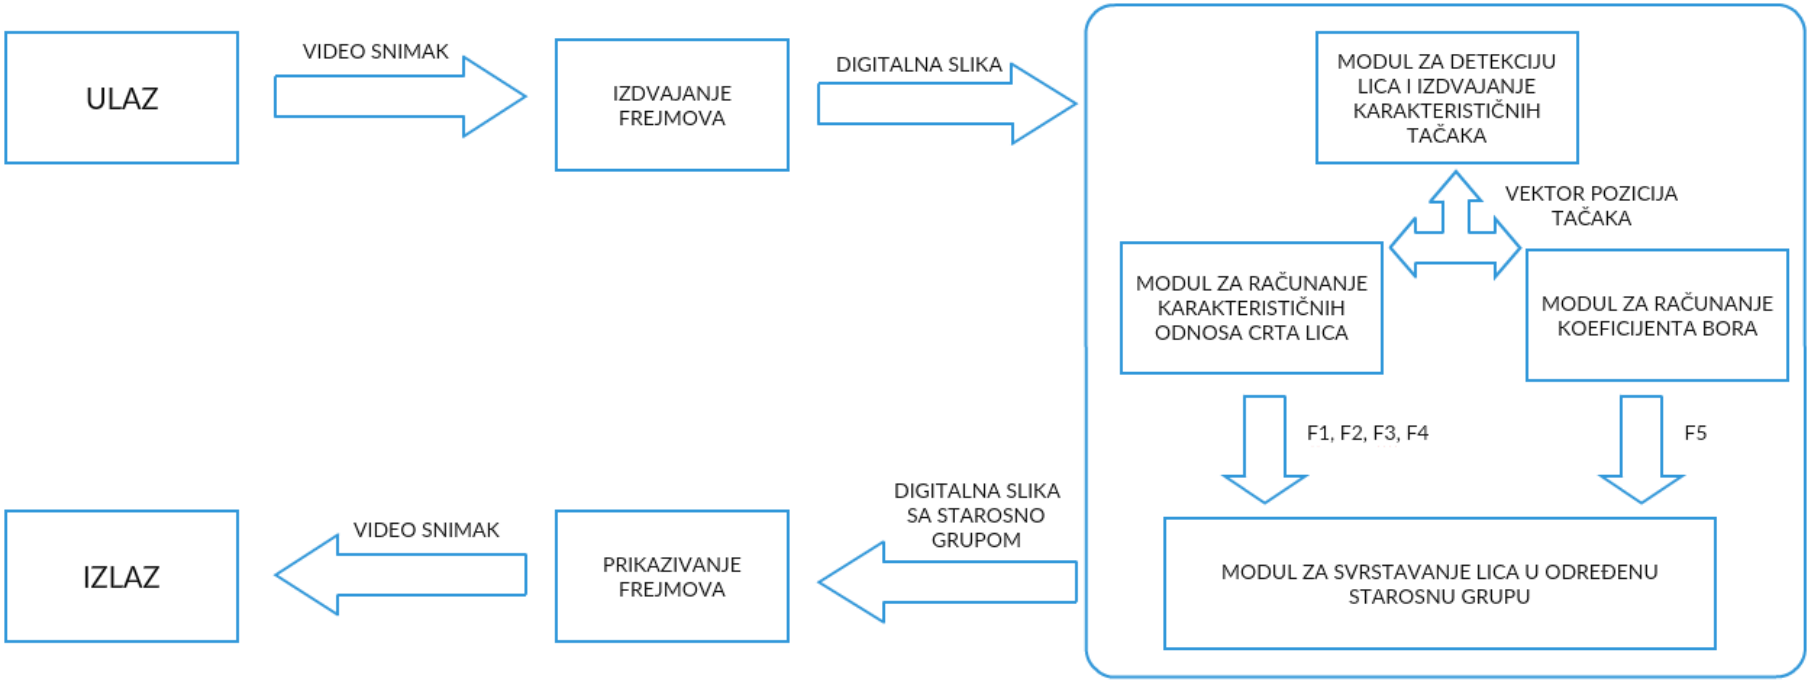
$$F4 = \frac{udaljenost\ oka\ i\ vrha\ nosa}{udaljenost\ oka\ i\ usne}$$

Mlađi odrasli → Stariji odrasli

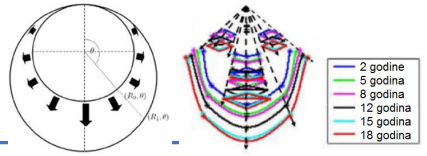


F_5 = procenat bora na licu

Konceptualni model sistema

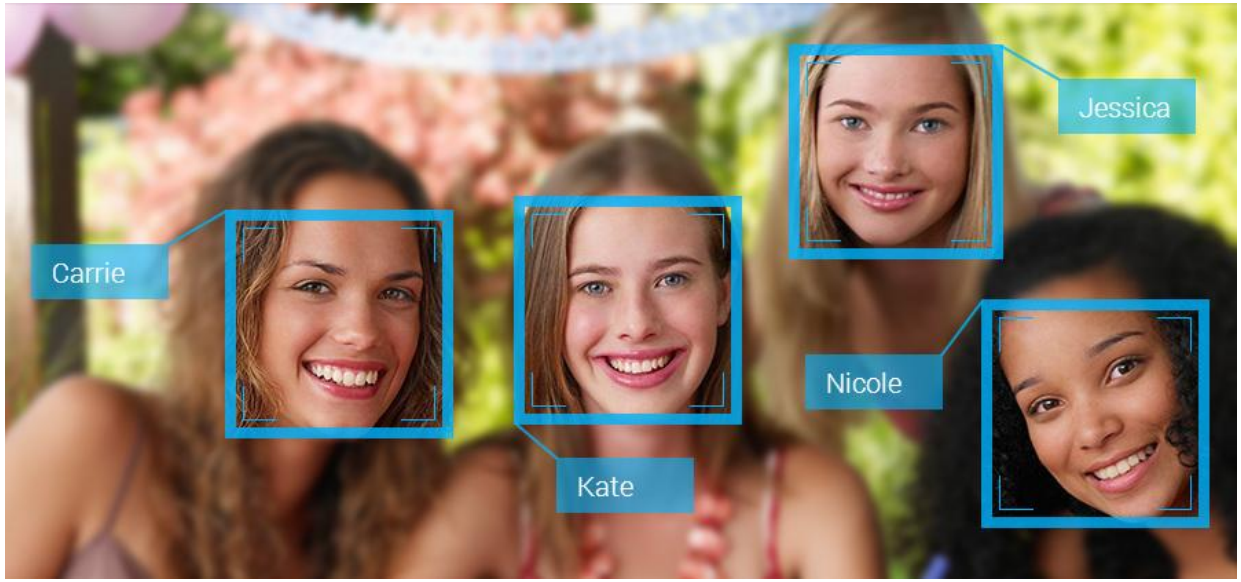


Detekcija lica na slici

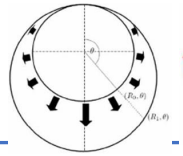


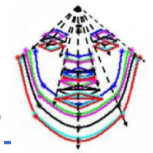
- Detektor iz *dlib* biblioteke
  - Ovaj detektor se oslanja na HOG + *sliding window*

- Svako pronađeno lice se iseca sa slike i svaki isečak se nadalje posebno obrađuje

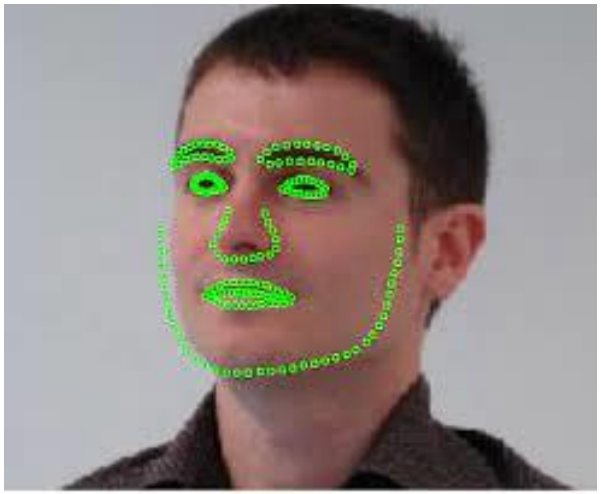


Detekcija karakterističnih tačaka lica

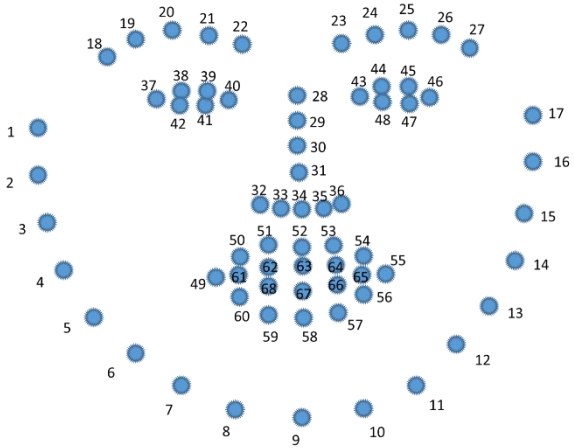






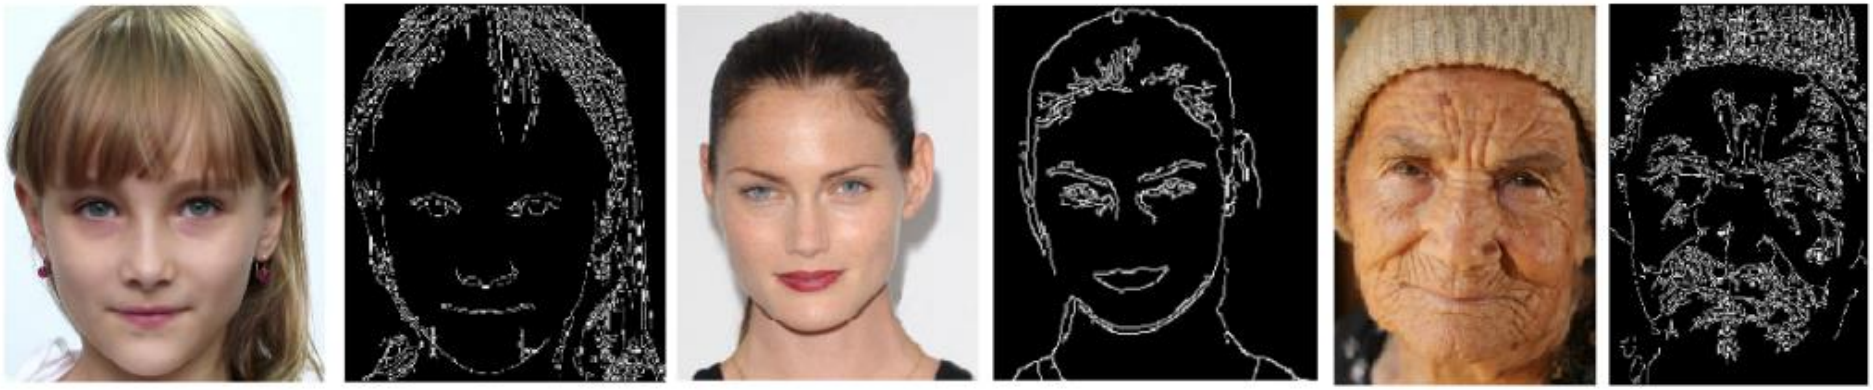


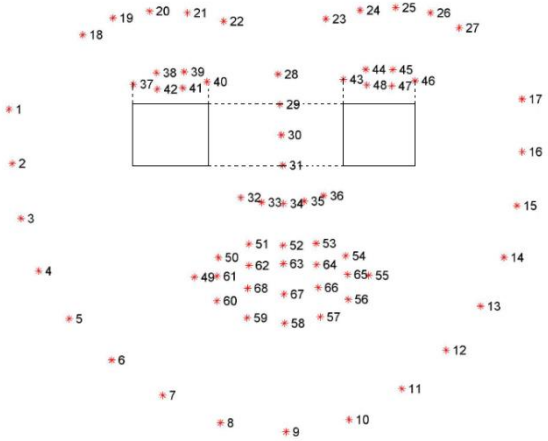
- *dlib* detektor
- Bazira se na treniranju modela (*train* skup sastavljen od slika na kojima su ručno označene koordinate)
- Računamo F1-F4



Bore







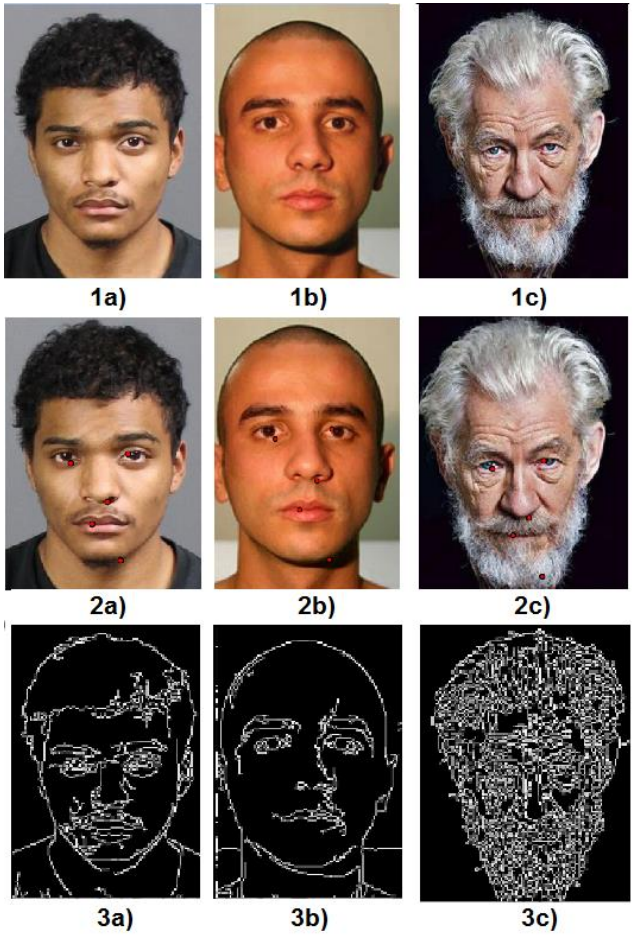
$$F5 = \frac{broj\ belih\ piksela}{ukupan\ broj\ piksela}$$

Modul za svrstavanje lica u starosnu grupu

- Svaka slika je reprezentovana karakterističnim odnosima lica ($F_1 - F_4$) i koeficijentom bora (F_5)
- Izlaz predstavlja jedna od tri starosne grupe
- Isprobani su
  - neuronska mreža 66.7
  - K-NN 71%

K-NN – Analiza grešaka modela

- Algoritam je svu decu svrstao u odgovarajuću kategoriju

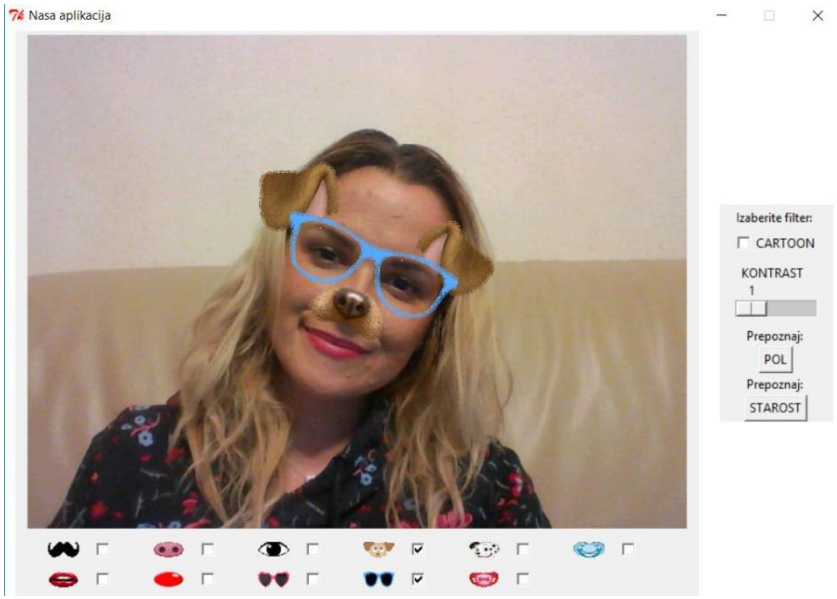


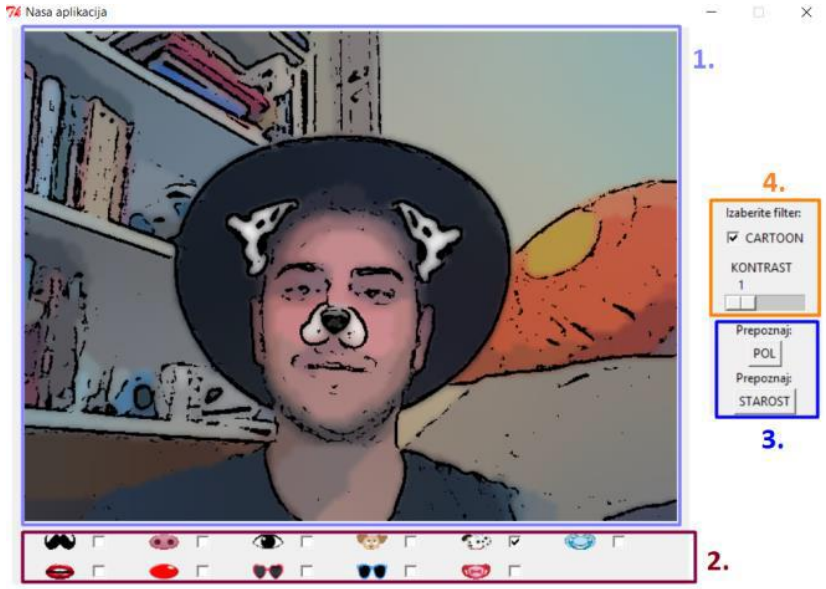
- Prve dve osobe su mlađi odrasli svrstani u kategoriju dece
  - Njihov vrh brade je na višoj poziciji od proseka, što čini njihove antropometrijske odnose bliske dečijim
  - Sistem je tačno odredio malu količinu bora u regiji obraza
- Treća osoba je klasifikovana kao mlađi odrasli
  - Razlog je zaklonjenost lica bradom što je uticalo na računanje antorpometrijskih odnosa – vrh brade je označen niže nego što jeste
  - Količina bora je dobro određena

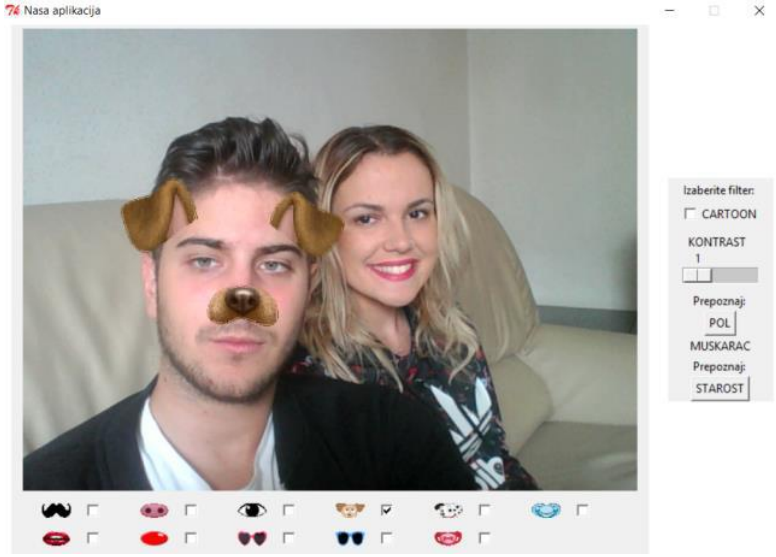
Nedostaci

- Radi dobro samo za lica okrenuta kameri
- Rezolucija snimka utiče na tačnost
- Zaklonjenost delova lica
- Ožiljci na licu i bore nastale usred facijalne ekspersije
- Region čela bi takođe mogao biti uzet u obzir za računanje bora, ali je problem razlikovanje kože od kose

Slični projekti







https://github.com/ftn-ai-lab/sc-2016-e2/issues/44

Slični projekti

Utvrđivanje istinitosti iskaza osobe sa video snimka

- Tehnike kojima se koriste FBI agenti
  https://www.businessinsider.com/how-to-tell-someones-lying-by-watching-their-face-2016-1/
  - Broj treptaja (5-6 sukcesivnih treptaja u stresnim situacijama, uobičajeno 5-6 treptaja u minuti) – Blink Detector
  - Stiskanje usana – Pursed Lips Detector
  - Pojava rumenila u licu ispitanika – Blushing Detector
  - Učestalo skretanje pogleda
  - Preznojavanje
  - Odmahivanje glavom
  - Dodirivanje lica...

https://github.com/ftn-ai-lab/sc-2017-siit/issues/20

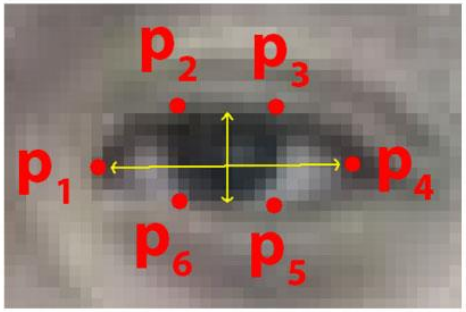
Blink detector

- EAR vrednost – *eye aspect ratio*

Tereza Soukupova and Jan Cech, Real-Time Eye Blink Detection using Facial Landmarks, 2016, http://vision.fe.uni-lj.si/cvww2016/proceedings/papers/05.pdf

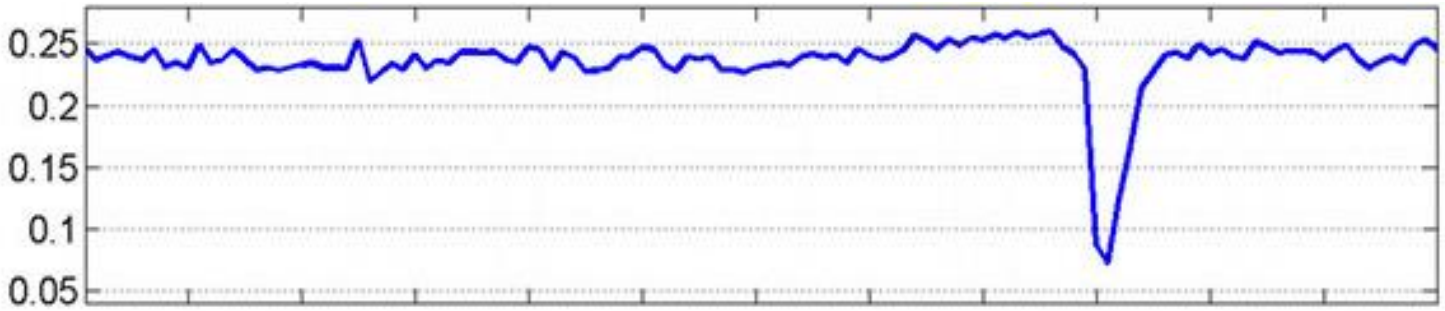


$$EAR = \frac{\|p_2 - p_6\| + \|p_3 - p_5\|}{2 * \|p_1 - p_4\|}$$



Prediktovane tačke očiju kada ih osoba drži zatvorenim. EAR vrednost iznosi 0.1230

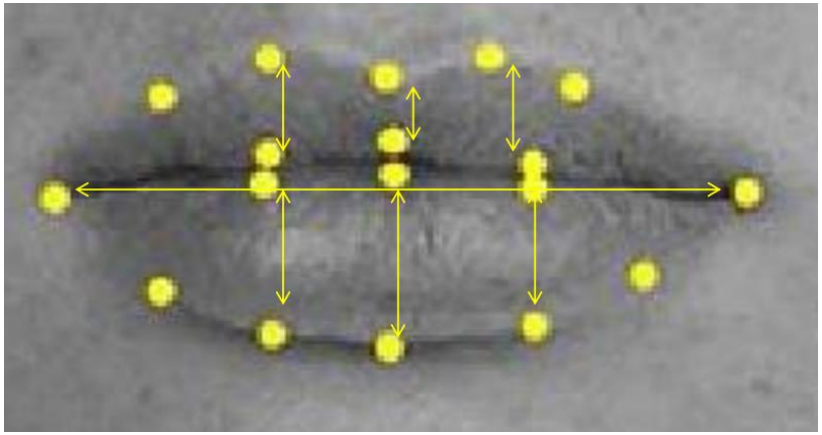
→ Prag treptaja za svakog ispitanika



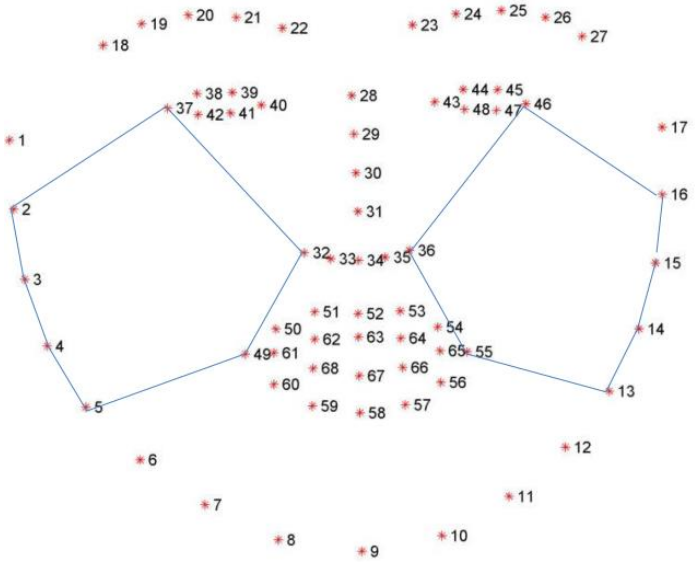
EAR vrednost u trenutku treptaja

Pursed Lips Detector

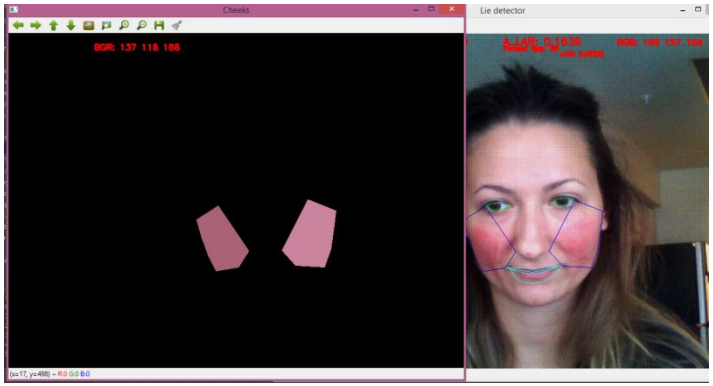
- LAR vrednost: *lips aspect ratio*
- Prag: 0.8*LAR



Blushing detector



Regioni obraza

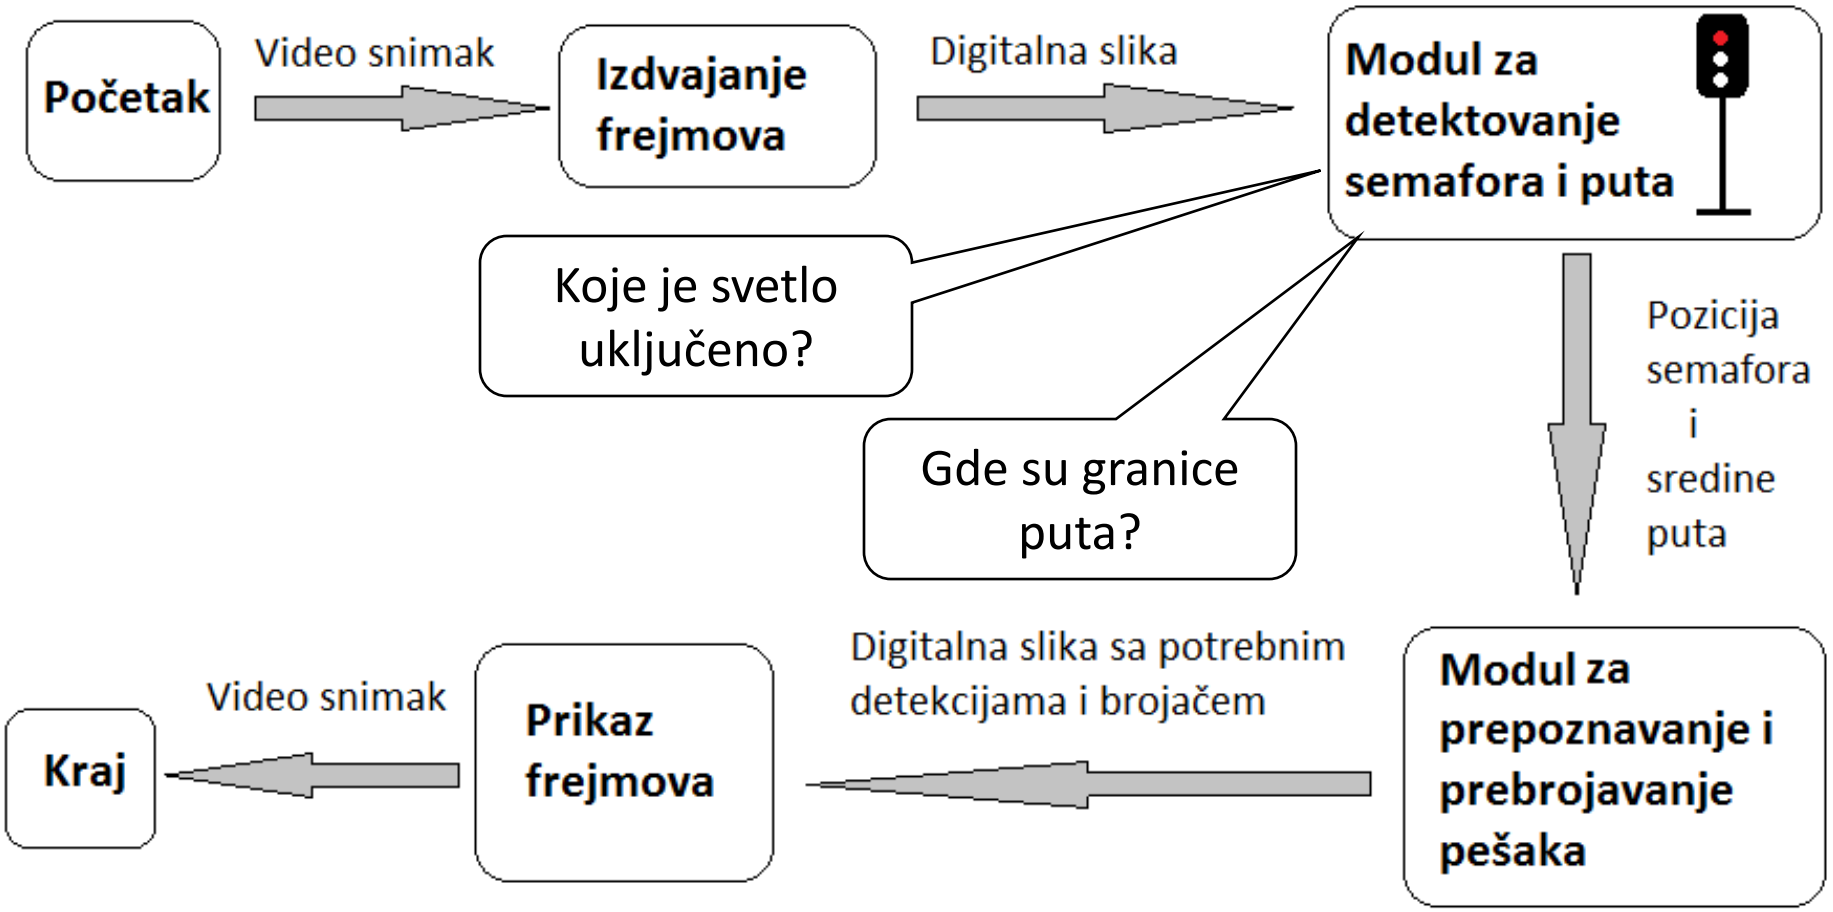


- Prvobitna, naivna implementacija: prilikom crvenila dolazi do rasta samo crvenog kanala RGB
- Međutim, u slučaju okretanja lica ka svetlosti, vrednosti sva tri kanala se naglo uvećavaju
- Stoga je u obzir uzet prag koji mogu da pređu vrednosti crvenog, plavog i zelenog kanala kao i ukupna promena vrednosti sva tri kanala

Detekcija pešaka koji su prešli pešački prelaz na crveno svetlo

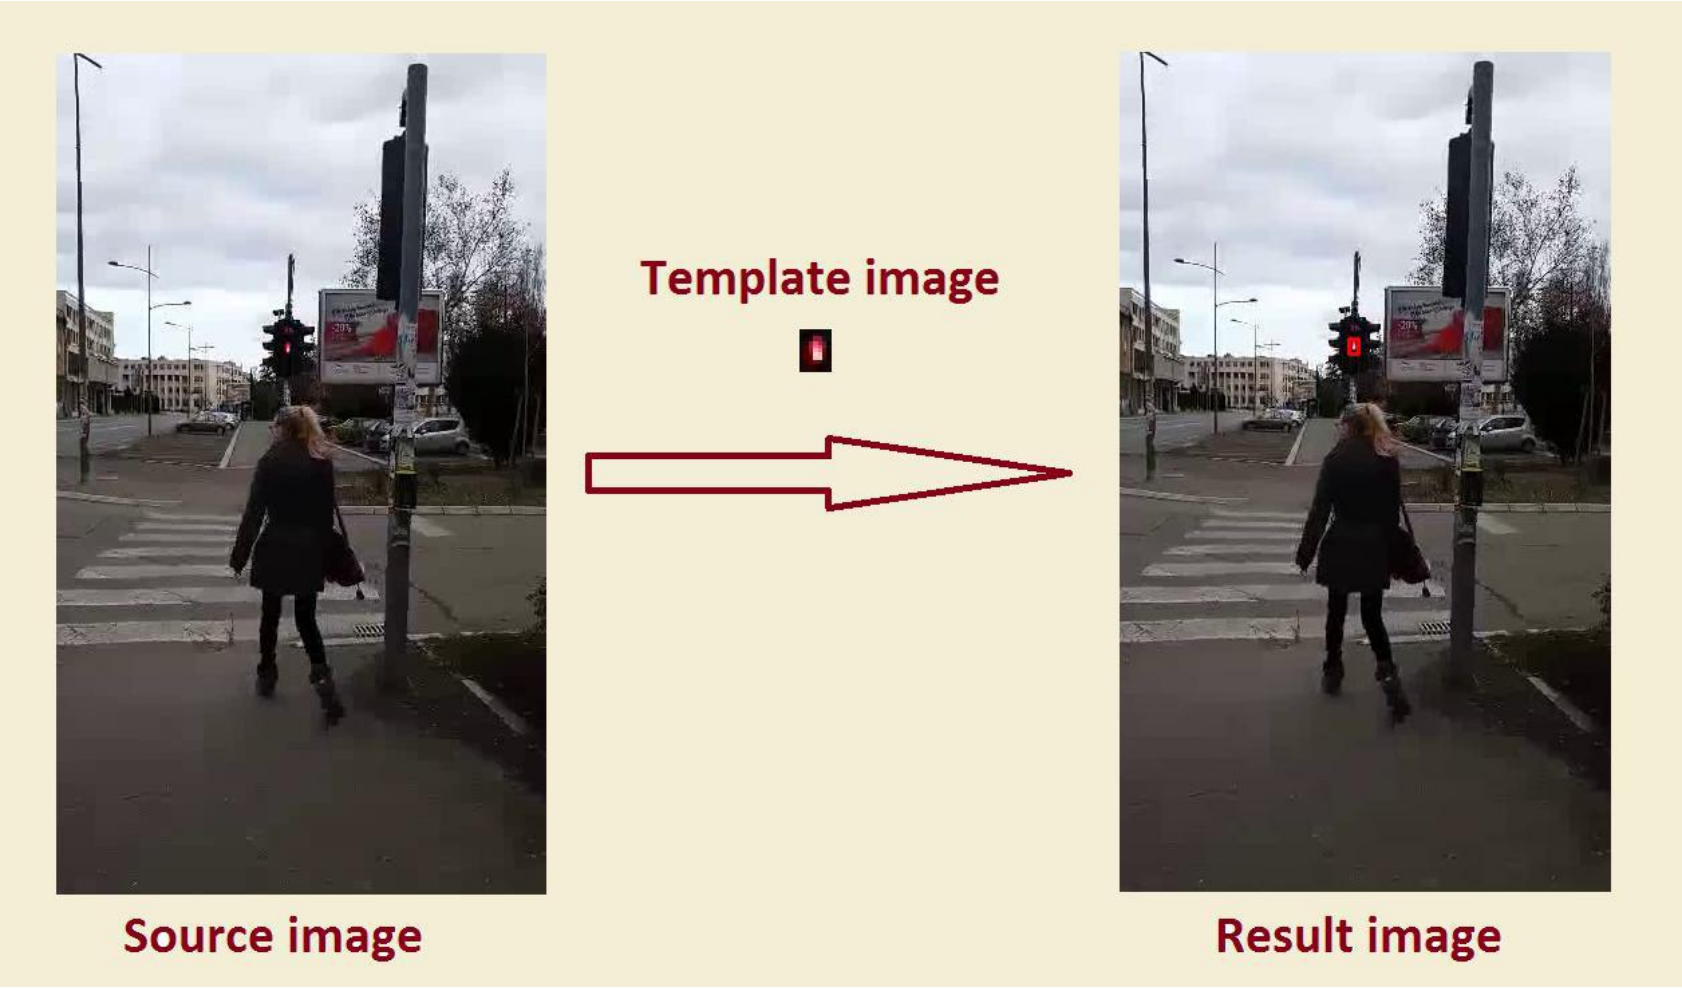
- Jelena Janković i Tamara Mrkšić
- https://github.com/ftn-ai-lab/sc-2016-e2/issues/90
- Materijali prezentovani ovde preuzeti su iz diplomskog rada autora Tamare Mrkšić

Konceptualni pregled sistema



Detekcija crvenog svetla na semaforu

- Primenjen je *Template matching* (pronalaženje dela slike koji se najviše podudara sa uzorkom)



Detekcija puta

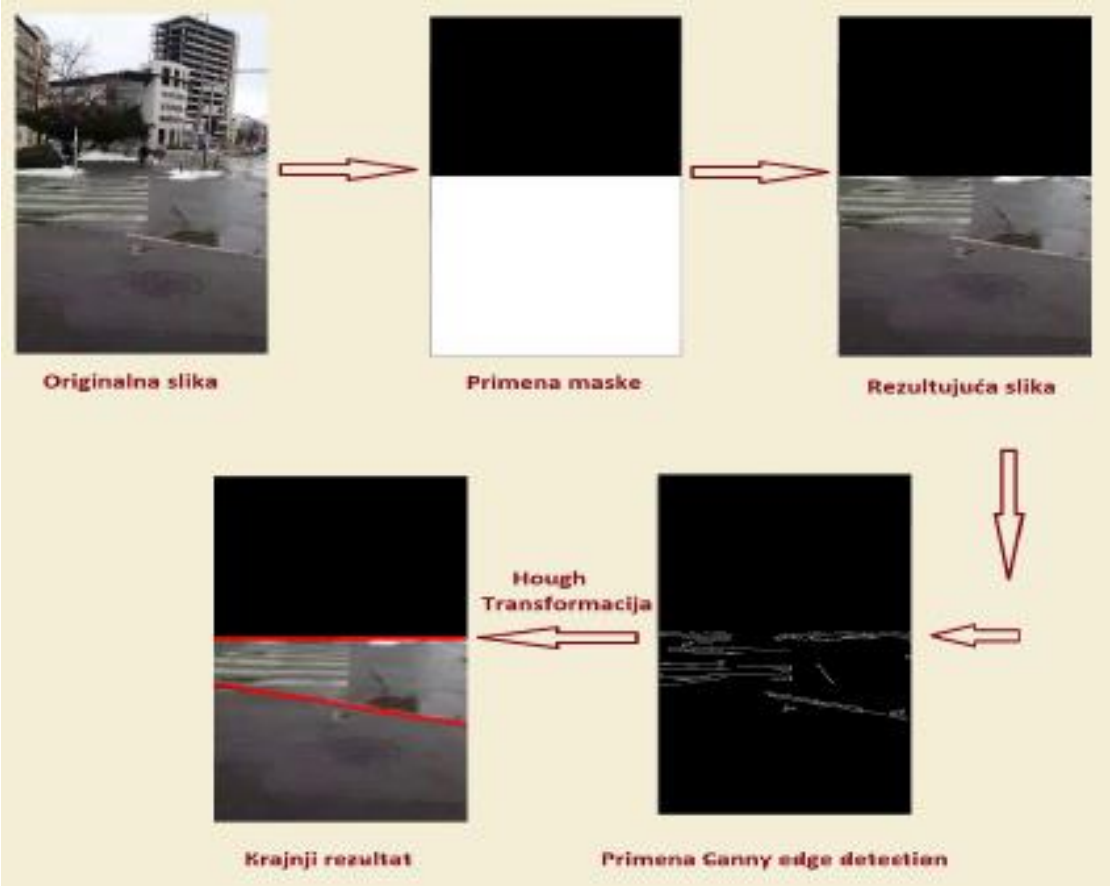
1. Učitava se slika u boji
2. Pomoću *Canny edge detection* tehnike su detektovane ivice – rezultat je binarna slika
3. Primenjena je *Hough* transformacija
4. Postavljen je prag za detekciju svih linija



rezultati nisu bili zadovoljavajući, jer je previše ivica prepoznato

Detekcija puta

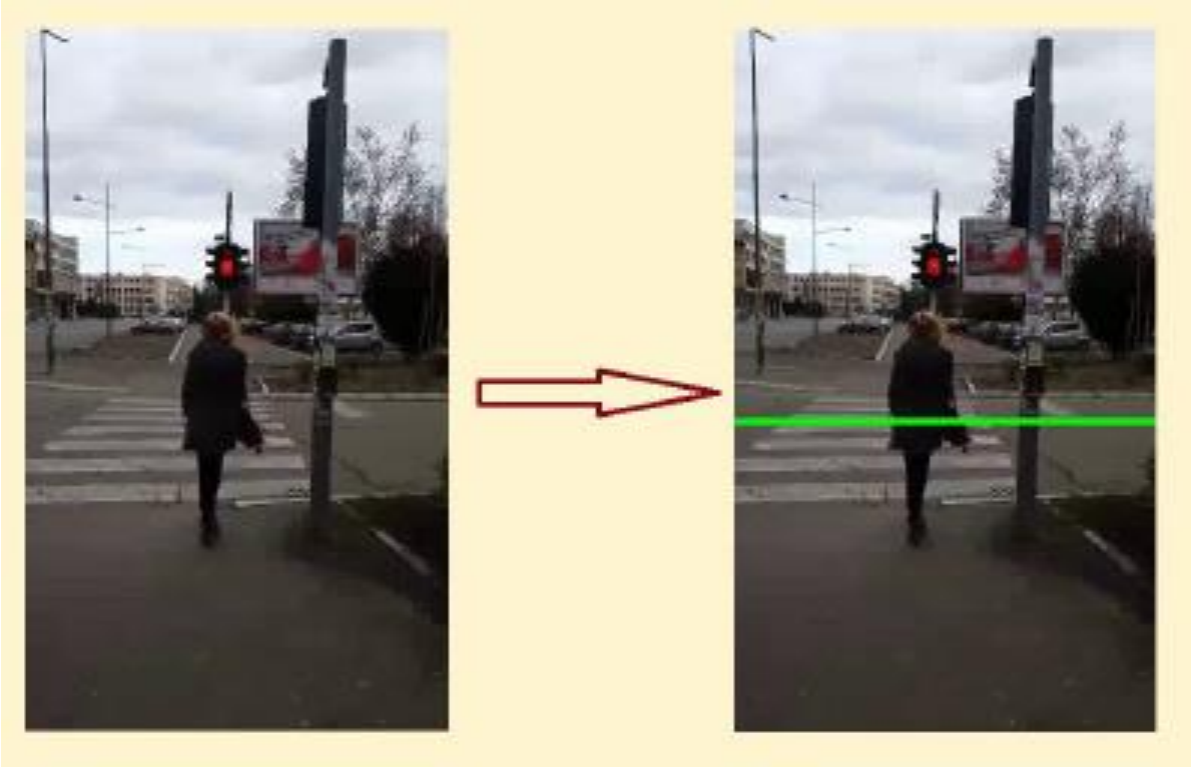
- Rešenje: koristiti masku kako bi se uklonili nepotrebni delovi slike



Radilo je bolje, ali rezultati nisu uvek bili zadovoljavajući

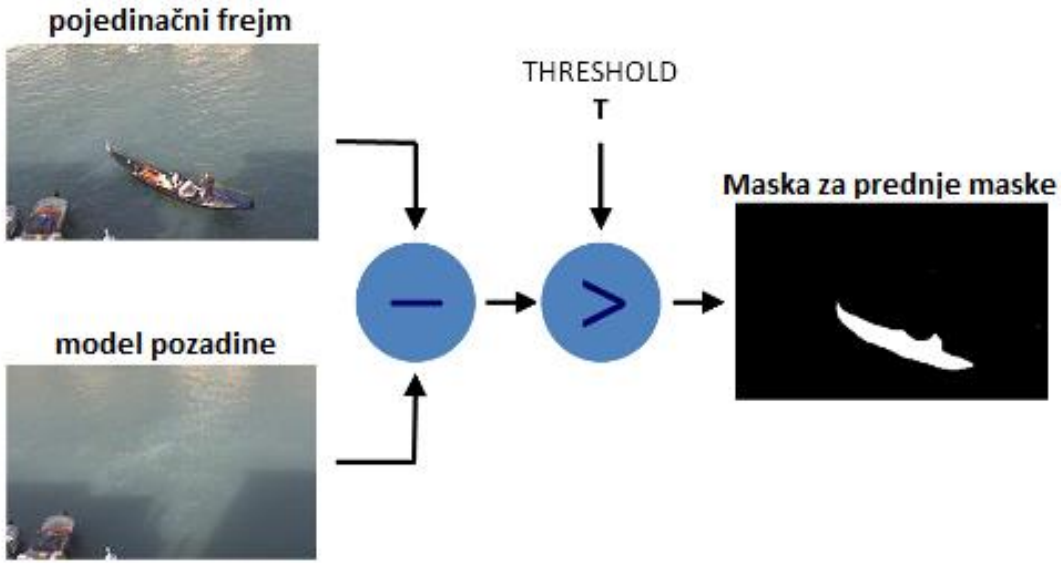
Detekcija puta

- Snimci su napravljeni sa mesta, koje je jednako udaljeno od semafora i pešačkog prelaza
- Na osnovu detektovane pozicije semafora određena je približna pozicija sredine pešačkog prelaza



Modul za prepoznavanje pešaka

- Potrebno je da izdvojimo pešaka od pozadine
  - Oduzimamo trenutni kadar od pozadineskog modela (statički deo scene)



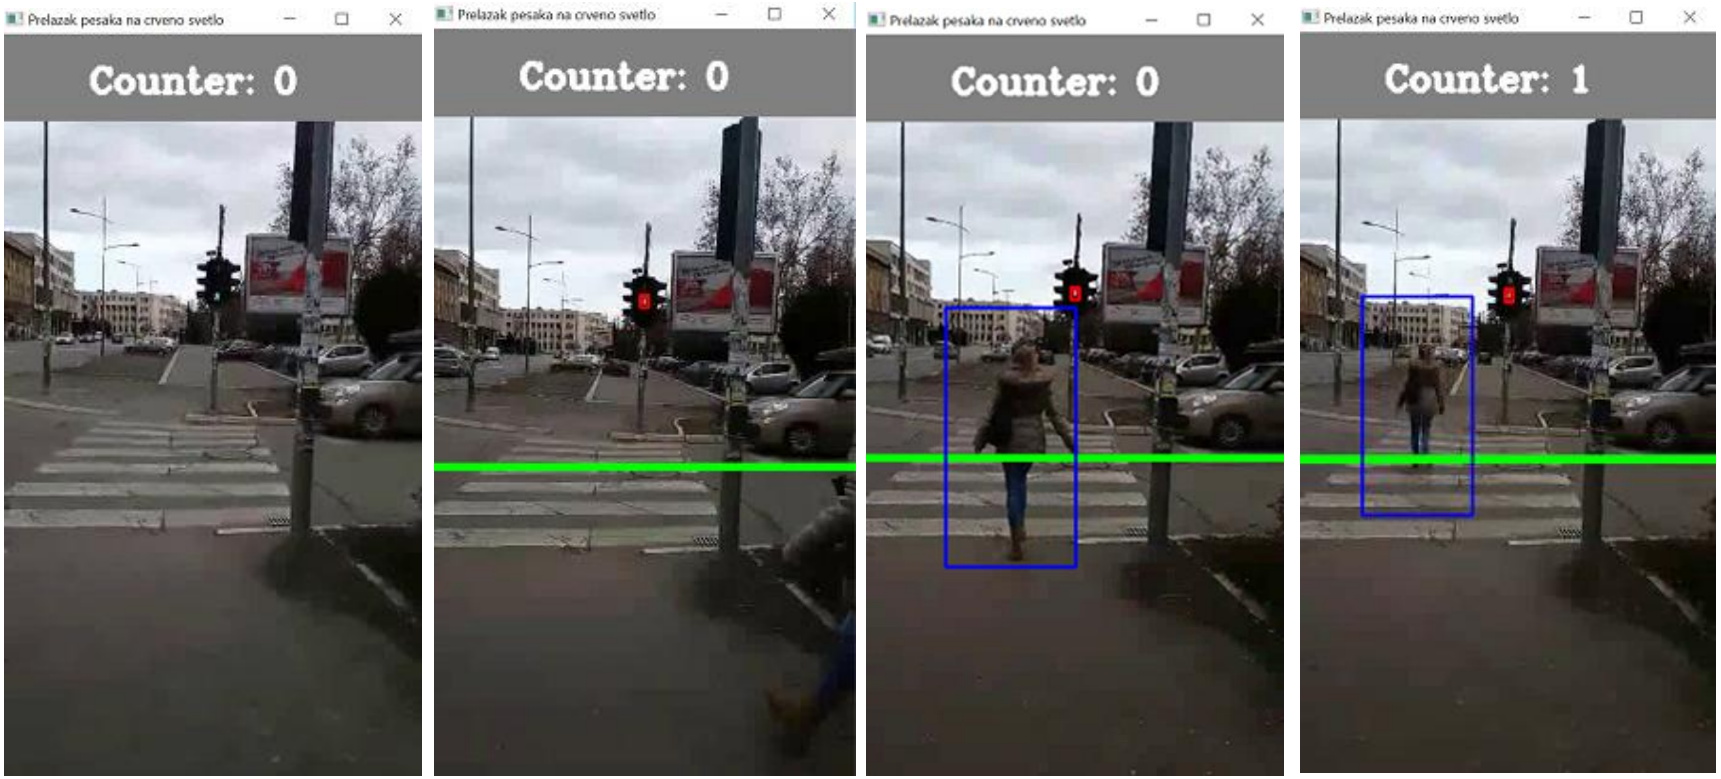
- Najpoznatiji algoritmi ovog tipa su MOG, MOG2 i GMG
  - http://docs.opencv.org/trunk/db/d5c/tutorial_py_bg_subtraction.html

Modul za prepoznavanje pešaka

- Problem:
  - snimci nisu napravljeni pomoću stacionarne kamere (korišćen je mobilni telefon)
  - Sve je prepoznavano kao pokret

- Zbog toga je umesto MOG primenjen *Haar Cascade Classifiers*
  - Metod detekcije objekata zasnovan na mašinskom učenju
  - U zadovoljavajućoj meri je prepoznato kretanje pešaka uz korišćenje klasifikatora za prepoznavanje celog tela
  - http://docs.opencv.org/3.1.0/d7/d8b/tutorial_py_face_detection.html

Verifikacija

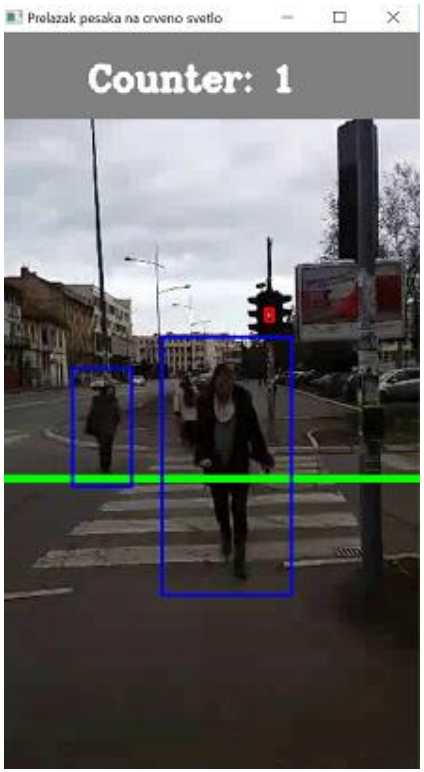


Nedostaci u rešavanju ovog problema

- Pozicija kamere
  - Semafor ne sme biti previše blizu niti daleko (neće se videti svi pešaci)
  - Kamera ne sme biti suviše visoko zbog klasifikatora koji prepoznaju telo pešaka
- Stacionarnost kamere
  - Stacionarna kamera bi znatno pobojšala rezultate
  - Pomogli bi i algoritmi i tehnike za dodatnu stabilizaciju video snimka
- Osvetljenje
  - Različito ponašanje u zavisnosti od doba dana
  - Različiti uslovi za sunčano i kišovito vreme
  - Primena algoritama i tehnika za automatsko prilagođavanje u zavisnosti od uslova osvetljenosti

Nedostaci u rešavanju ovog problema

- Grupa pešaka
  - Ako mnogo pešaka odjenom prelazi na crveno, pogoršala bi se tačnost prepoznavanja pešaka
- Smer kretanja pešaka
  - Pretpostavka sistema je da se pešaci kreću ortogonalno u odnosu na smer ulice
- Pešak iza pešaka



Prepoznata su dva umesto tri pešaka

Detekcija i prepoznavanje brend logoa na slici

- Željko Drageljević, Milan Desančić, Vladimir Inđić

- https://github.com/vladaindjic/brand-logo-detection

Problem

- Prepoznavanje brenda čiji je logo prikazan na slici
- Flickr Logos 27 dataset
  - Slike logoa 27 brendova (za svaki 30 slika)



Nekoliko slika iz skupa podataka koje sadrže logo brenda

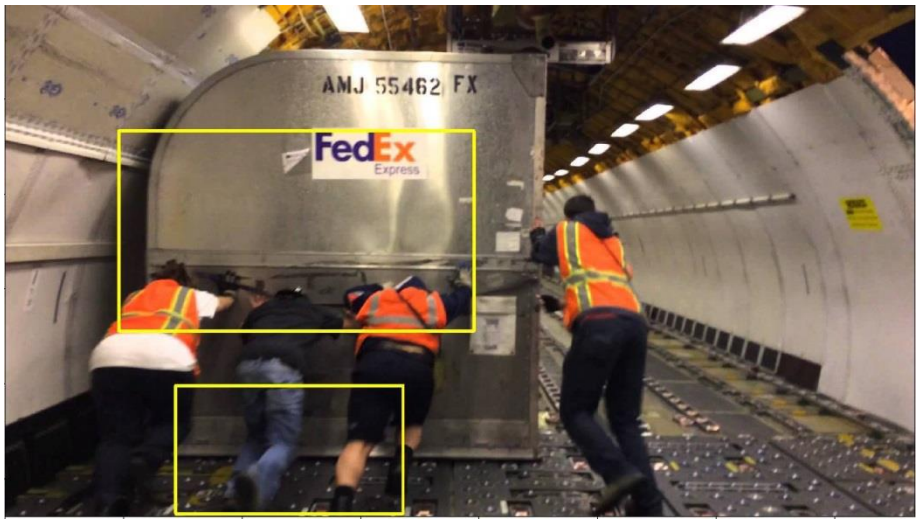


Nekoliko slika koje ne sadrže logo

- Slike lošijeg kvaliteta su ručno izdvojene i zamenjene slikama sa interneta
- Augmentacija: generisano je po 500 slika za svaki logo (rotiranje, isecanje, dodavanje šuma, *blur*,...)
- Pridodate su slike koje ne sadrže logoe
- Podela na skup za treniranje (70%), validaciju (10%) i testiranje (20%)

Metodologija

1. HOG + Neuronska mreža + *Sliding Window* + *Non-Maximum Supression* (NMS)
   - Ukoliko je izdvojeno više karakterističnih regiona sa logoima, na njih se primenjuje NMS
   - NMS – na osnovu površine preklapanja regiona i pouzdanosti predikcije postojanja logoa unutar njih, izdvajaju se najbolji regioni i oni predstavljaju rezultat detekcije



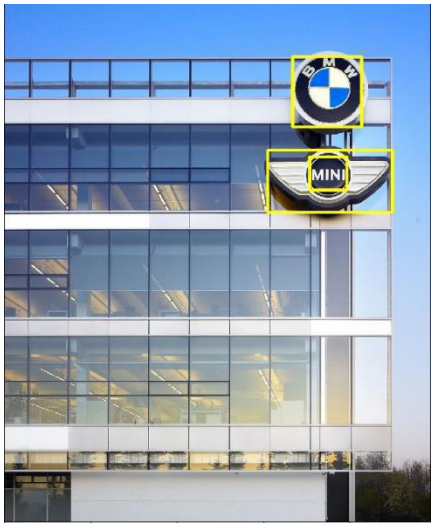
Uspešno detektovanje znaka FedEx, ali takođe i detektovanje logoa tamo gde on ne postoji

Metodologija

2. CNN + *Selective Search + Non-Maximum Suppression*
   - *Selective Search* – dostupna implementacija u *OpenCV.* Grupiše i izdvaja regione na slici koji su slični po određenim karakteristikama (boji, teksturi,...)
   - Izdvojeni regioni se puštaju na ulaz CNN
   - Ukoliko je izdvojeno više regiona sa logoima, na njih se primenjuje NMS







Zaključak

- Oba pristupa bila su veoma uspešna pri rešavanju zadatka klasifikacije
  - NM: 96.7%, CNN: 99.8%
- Prvi metod je imao loše rezultate prilikom detekcije, pre svega zbog *sliding window* pristupa
  - Skup
  - Veličina prozora se mora predefinisati, a logoi imaju različit oblik i dimenzije
- Drugi metod je imao bolje rezultate prilikom detekcije
  - Pokazao je kako je smislena pretraga regiona važna za ovaj problem
- *State-of-the-art* za detekciju objekata: R-CNN, Fast R-CNN i Faster R-CNN