Test 1 - Jednostruka linearna regresija

1. Zaokružite tačne iskaze:
   a. Linearna regresija spada u nadgledano obučavanje.
   b. Linearnom regresijom predviđamo binarnu varijablu na osnovu kontinualne varijable.
   c. Linearna regresija modeluje odnos dve kontinualne varijable.
   d. Kod jednostruke linearne regresije modelujemo y na osnovu više ulaza x.
   e. Moguće je konstruisati model linearne regresije koristeći neuronsku mrežu.

2. Napišite formulu za jednostruku linearnu regresiju: $h_\theta = \theta_0 + \theta_1 x$. Zaokružite parametre ovog modela.

3. Zaokružite metrike adekvatne za evaluaciju regresionog modela: accuracy, cross-entropy loss, mean squared error, F-measure, R^2.

4. Dat je sledeći trening skup:

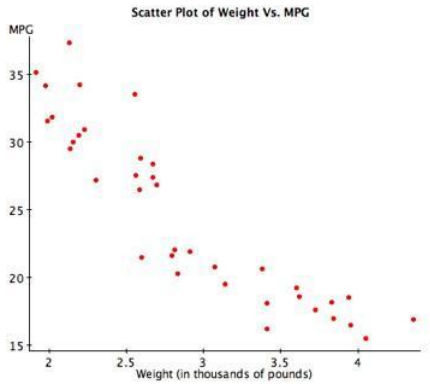
x	1	2	4	0
y	0.5	1	2	0

Ako biste ove podatke iskoristili za treniranje modela linearne regresije, koje vrednosti biste dobili za θ_0 i θ_1?

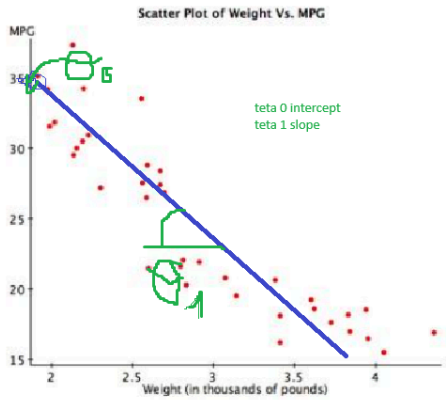
(a) $\theta_0 = 0.5, \theta_1 = 0$ (b) $\theta_0 = 0.5, \theta_1 = 0.5$ (c) $\theta_0 = 1, \theta_1 = 0.5$ (d) $\theta_0 = 0, \theta_1 = 0.5$ (e) $\theta_0 = 1, \theta_1 = 1$

5. Ako imamo $\theta_0 = -1, \theta_1 = 0.5$, koliko je $h(4)$, a koliko $J(\theta_0, \theta_1)$? h(4)=-1+0.5*4=1 a $J(\theta_0,\theta_1)=(1-2)^2$

6. Na grafiku skicirajte model i označite šta predstavljaju parametri modela.



MPG – *Miles Per Gallon* (koliko milja automobil pređe sa galonom goriva)



teta0 - presek sa y osom, nema interpretaciju jer nema smisla

teta1 - nagib prave, koliko milja automobil predje manje ako se broj galona smanji za 1000

7. Minimalna vrednost funkcije greške linearne regresije je 0, a maksimalna beskonacno. Skicirajte tipičan oblik funkcije greške linearne regresije. **Ima slika na kraju testa**

8. Neka je data funkcija greške (θ_0, θ_1) koja vraća realan broj i ima više lokalnih optimuma. Primenom gradijentnog spusta (GD) minimizujemo f i odabrali smo *learning rate* α. Zaokružite tačne iskaze:

a. Čak i za veliko α, svaka iteracija GD će smanjiti vrednost f.
b. Ako α ima previše nisku vrednost, GD će trebati puno vremena da konvergira.
c. Ako su θ_0 i θ_1 u lokalnom optimumu, jedna iteracija GD neće promeniti njihovu vrednost.
d. Ako su $_0$ i θ_1 inicijalizovani tako da važi $\theta_0 = \theta_1$, onda će nakon jedne iteracije GD, i dalje biti $\theta_0 = \theta_1$.
e. Ako prve iteracije GD rezultuju uvećanjem vrednosti (θ_0, θ_1), verovatno smo postavili preveliko α
f. Bez obzira na inicijalizaciju θ_0 i θ_1, uz dobar odabir α, GD će sigurno konvergirati u isti optimum.
g. Postavka α na malu vrednost nije štetno i može samo da ubrza kovergenciju GD.

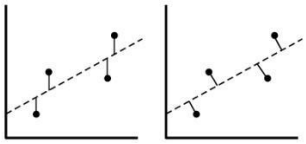
9. Neka smo pomoću GD uspeli da pronađemo minimum funkcije greške za model linearne regresije takav da važi $J(\theta_0, \theta_1) = 0$. Koji od sledećih iskaza su tačni:

a. Da bi ovo bilo moguće, moramo imati $y^{(i)} = 0$ za svaki primer iz trening skupa.
b. GD se "zaglavio" u lokalnom optimumu.
c. Da bi ovo važilo, sigurno je $\theta_0 = 0$ i $\theta_1 = 0$, tako da model uvek vraća $h(x) = 0$.
d. Trening skup je takav da svi primeri perfektno leže na pravoj liniji.
e. Možemo perfektno da predvidimo vrednost y čak i za nove primere (koji nisu bili u trening skupu).
f. Ovo nije moguće – ne postoje vrednosti θ_0 i θ_1 za koje važi $(\theta_0, \theta_1) = 0$.

10. Tačno ili netačno: Linearna regresija je osetljiva na *outlier-e*. Tacno

11. Šta je od sledećeg tačno za reziduale: (a) manje vrednosti su bolje (b) veće vrednosti su bolje (c) a ili b, zavisno od situacije (d) nijedan od ponuđenih odgovora nije tačan. Rezidual je odstupanje predikcije od stvarne vrednosti

12. Koja od ilustrovanih rastojanja koristimo da bismo uklopili model linearne regresije?



a) slika levo
b) slika desno
c) zavisi od situacije
d) nijedan od ponuđenih načina.

13. Neka za model fitovan na podacima iz zadatka 6 važi da je $\theta_0 = 48.8$, a $\theta_1 = -8.37$.

(a) Kako interpretirate vrednost obeležja θ_0?

nema smislenu interpretaciju jer ne postoji vozilo tezine 0

(b) Kako interpretirate vrednost obeležja θ_1?

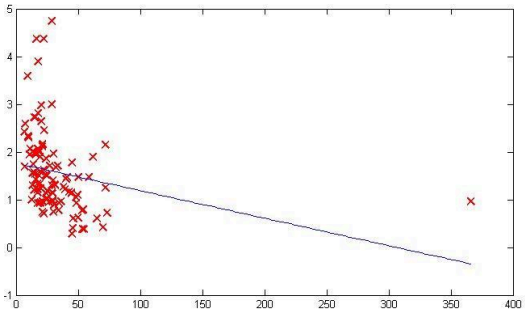
za svakih 1000 funti tezine, broj milja po ghalonu opadne za 8.37

14. Zaokružite tačne odgovore:

a. Ne moramo birati nikakve parametre kada tražimo rešenje pomoću *Gradient Descent.*
b. Ne moramo birati nikakve parametre kada tražimo rešenje pomoću *Normal Equation.*
c. Preferiramo *Normal Equation* u slučaju velikog broja obeležja.

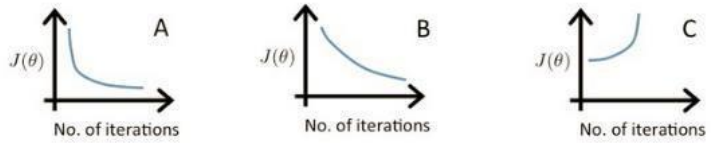
d. *Normal Equation* je iterativan algoritam.
e. Uvek možemo pronaći rešenje primenom *Normal Equation.*

15. Kako biste unapredili sledeći model?



Izbacili outliere, konkretno ovaj skroz desno

16. Šta od navedenog je tačno za *learning rates* α_A, α_B i α_C koji su proizveli sledeće grafike?



a) $\alpha_A < \alpha_B < \alpha_C$

b) $\alpha_B < \alpha_A < \alpha_C$

c) $\alpha_A = \alpha_B = \alpha_C$

d) Ne možemo zaključiti o a) – c) na osnovu grafika

Test 2 -Višestruka linearna regresija

1. Tačno ili netačno:
    a. *Overfitting* je verovatniji kada postoji velika količina podataka za treniranje.
    b. *Overfitting* je verovatniji ako imamo veliki broj obeležja.
    c. *Overfitting* je verovatniji ako koristimo fleksibilan (kompleksan) model.
    d. *Overfitting* je verovatniji ako smo uočili da su vrednosti parametara dobijenog modela male.
    e. Verovatnije je da će model $y = \theta_0$ patiti od velike varijanse nego od velikog sistematskog odstupanja. **(netacno jer ne moze uhvatiti slozenost podataka jer je jednostavan)**
    f. Za fiksan model, ako povećavamo trening skup, očekujemo da vrednosti parametara modela θ rastu.

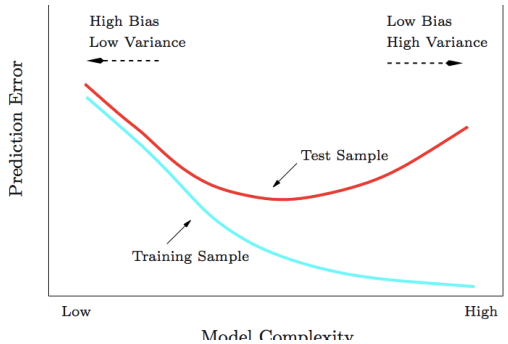
2. Zamislite da ste na skupu podataka trenirali model linearne regresije 3. stepena polinoma i otkrili da su trening i test greška jednake 0 (odnosno, da se model savršeno uklapa u podatke).

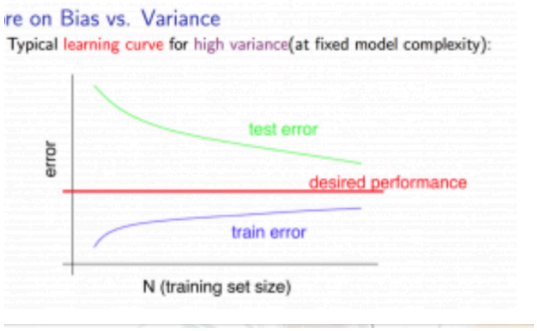
    a. Šta očekujete za polinom 4. stepena? (1) verovatnoća *overfitting*-a je velika; (2) verovatnoća *underfitting*-a je velika; (3) ne možemo reći; (4) nijedan od ponuđenih odgovora.

    b. Šta očekujete za polinom 2. stepena? (1) verovatnoća *overfitting*-a je velika; (2) verovatnoća *underfitting*-a je velika; (3) ne možemo reći; (4) nijedan od ponuđenih odgovora.

    c. Šta će se desiti ako koristite polinom 2. stepena? Sistematsko odstupanje će biti vece, varijansa će biti mala. (malo/veliko)

3. Na grafiku levo nacrtajte kako se ponaša (a) trening (b) test greška. Na grafiku desno nacrtajte kako se ponaša (a) trening i (b) test greška ako je **kompleksnost modela fiksirana**.





4. Na levom grafiku označite koji deo odgovara *overfitting*-u, a koji *underfitting*-u.

5. Na levom grafiku označite koji deo odgovara velikom sistematskom odstupanju, a koji varijansi.

6. Recimo da ste odabrali model optimalne kompleksnosti. Nakon toga ste identifikovali obeležje koje je veoma relevantno za rešavani zadatak. Šta očekujete da će se desiti ako dodate ovo obeležje u model? Trening greška će se smanjiti. Greška na validacionom skupu će se smanjiti. (uvećati/smanjiti)

7. Za svaku od tehniku naznačite da li imaju potencijal da **redukuju** sistematsko odstupanje (bias) i/ili varijansu:

	Bias	Varijansa
Uvećanje fleksibilnosti modela (npr. dodavanje slojeva/neurona u neuronsku mrežu)	X	
Primena *feature engineering* (npr. izmena ili dodavanje obeležja prema uvidima proisteklim iz analize grešaka modela)	X	X
Selekcija obeležja da bi se smanjio broj obeležja		X

Early stopping (zaustaviti *gradient descent* ranije, zasnovano na grešci validacionog skupa)		X
Izmena modela (npr. izmena arhitekture neuronske mreže)	X	X
Dodavanje više trening podataka		X

8. Možemo li **linearnom** regresijom modelovati **kvadratnu** funkciju? Da (polinomijalna regresija)

9. Trening skup služi za treniranje modela, validacioni skup služi za podesavanje hiperparametara modela, a test skup služi za nepristrasnu procenu performansi modela. Test skupom aproksimiramo generalizacijsku grešku.

10. Šta je „idealna“ stratifikacija, a šta obično radimo u praksi?

    "Idealna" stratifikacija podrazumeva da raspodela klasa ili karakteristika u skupu podataka bude identična u svakom od podskupova koji su kreirani, kao što su trening, validacioni i test skupovi. Ovo osigurava da svaki podskup odražava stvarnu raspodelu podataka, što može biti posebno važno u slučaju neuravnoteženih podataka ili kada je bitna specifična raspodela neke karakteristike.
    U praksi, često se ne postiže potpuno "idealna" stratifikacija zbog ograničenja podataka ili složenosti samog procesa uzorkovanja. Umesto toga, obično koristimo jednostavnije metode stratifikacije koje približavaju raspodelu klasa ili karakteristika u podacima, ali ne garantuju potpunu identičnost. Na primer, možemo koristiti slučajno uzorkovanje sa očuvanjem proporcija klasa ili upotrebu ugrađenih funkcija biblioteka za mašinsko učenje koje automatski vrše stratifikaciju prilikom podela podataka na trening, validacioni i test skup.

11. Kako biste stratifikovali podatke za regresiju, a kako za klasifikaciju?
    Klasifikacija - **Slučajno uzorkovanje sa stratifikacijom**- Podaci se slučajno uzorkuju, ali uz održavanje proporcija klasa u svakom podskupu. Ovo je korisno kada imamo neuravnotežene klase.
    Regresija - Slučajno uzorkovanje sa očuvanjem distribucije: Podaci se slučajno uzorkuju, ali se proporcija karakteristika održava u svakom podskupu.

12. Kada biste koristili podelu na trening i test skup, a kada unakrsnu validaciju?
    Trening test kada imamo dovoljno podataka, a validaciju kada imamo malo podataka mada ona pruza pouzdanije procene i sprecava overfitting

13. Imamo skup podataka. Radi brže konvergencije *gradient descent*-a normalizovali smo vrednosti obeležja. Nakon toga smo podelili skup podataka na trening, validacioni i test skup. Da li smo sve dobro uradili?
    Pa normalizacija obelezja vrsi se samo na osnovu podataka iz trening skupa

14. U slučaju **višestruke** regresije, šta je ključna stvar o kojoj moramo voditi računa prilikom interpretacije parametara modela?
    multikolinearnost ** videti ml teorija fajl za vise

15. Kako enkodiramo nominalna, a kako ordinalna kategorička obeležja?
    nominalna - one hot encoding jer ne postoji poredak
    ordinalna - label encoding jer postoji poredak

16. Šta je potencijalni problem prethodnog pristupa? Kako biste ga rešili?
    povecavanje kompleksnosti modela, prokletstvo dimenzionalnosti, teta je osteljivo na specificnosti trening skupa.
    Resenje je izbaciti jednu varijablu tj imati k-1 kategoriju

17. Multikolinearnost:

    je kada jendo obelezje predstavlja linearnu kombinaciju drugih obelezja

a. Nije problematična.
b. Nije problematična za performanse modela, ali troši računarske resurse.
c. Je nezgodna pri interpretaciji modela.
d. Može da se desi kod 1-*hot-encoding*-a

Test 3 - Regularizacija

1. Regularizacija je korisna za slučaj (selektujte sve tačne opcije):

   (a) *Overfitting*; (b) kada imamo obeležja u korelaciji; (c) prokletstva dimenzionalnosti (d) underfitting.

2. Napišite funkciju greške modela linearne regresije kada se primenjuje (a) *Ridge* (b) LASSO regularizacija.

$$J(\theta) = \frac{1}{2N}\sum_{i=1}^{N}\left(h_\theta(x^{(i)}) - y^{(i)}\right)^2 + \frac{\lambda}{2}\sum_{i=1}^{d}\theta_j^2$$

STA JE STA??

$$J(\theta) = \frac{1}{2N}\sum_{i=1}^{N}\left(h_\theta(x^{(i)}) - y^{(i)}\right)^2 + \lambda\sum_{i=1}^{d}|\theta_j|$$

3. Zamislite da ste trenirali kompleksan model linearne regresije na skupu podataka. Sada, koristite *Ridge* regresiju sa *penalty* λ. Odaberite opciju koja najbolje opisuje sistematsko odstupanje (*bias*):

   (a) U slučaju velikog λ, *bias* je mali; (b) U slučaju velikog λ, *bias* je veliki; (c) Ne možemo reći ništa o *bias*-u; (d) Nijedan od ponuđenih odgovora.

4. Šta se dešava kada primenite veliki *penalty* λ kod *Ridge* (L2) regularizacije? A šta kod LASSO (L1) regularizacije?

   (a) Neki koeficijenti će dobiti vrednost 0; (b) Neki koeficijenti će se približiti vrednosti 0, ali neće biti baš 0; (c) I a i b, u zavisnosti od situacije; (d) Nijedan od ponuđenih odgovora.
   Ridge - b)
   Lasso - a)

5. Za *Ridge* regresiju, šta znači da je $\lambda = 0$?

   a. Veliki koeficijenti θ nisu penalizovani
   b. Nije uračunat problem *overfitting*-a
   c. Funkcija gubitka je identična funkciji *ordinary least square (OLS) loss*.
   d. Sve iznad.

6. Tačno ili netačno:

   a. *Ridge* i *LASSO* su tehnike koje redukuju kompleksnost modela i sprečavaju *overfitting* koji može rezultovati iz primene jednostavne linearne regresije.

   b. *Ridge* regularizacija se može koristiti za selekciju važnih obeležja skupa podataka kod linearne regresije.

   c. *Ridge* regularizacija smanjuje kompleksnost modela ali ne smanjuje broj obeležja.

   d. Ako postoje dva ili više obeležja koje su u korelaciji, LASSO odabira jedno od njih na slučajan način. Ovo nije dobro za interpretaciju modela.

   e. Ako je broj obeležja *D* veći od broja primera *N*, LASSO će odabrati najviše *N* ne-nula obeležja, čak i u slučaju da su sva obeležja relevantna.

f. Ako uvećamo količinu podataka *N*, očekujemo da će nam trebati manje λ.

g. *Ridge* regresija smanjuje koeficijente modela i pomaže da redukujemo kompleksnost modela i rešimo problem multikolinearnosti.

h. Možemo koristiti *Gradient Descent* algoritam da treniramo LASSO.

i. Ne postoji *closed form solution* za LASSO.

j. *Ridge* regresija je korisna u slučaju kada imamo mnogo obeležja gde svako od njih doprinosi (u manjoj meri) predikciji ciljne funkcije

7. Primenjujete regularizaciju. Koje od opcija su tačne ako uvećavate regularizacioni parametar λ??????

(a) Uvećanje λ nikada neće smanjiti trening grešku.
(b) Uvećanje λ nikada neće uvećati trening grešku.
(c) Uvećanje λ nikada neće smanjiti test grešku.
(d) Uvećanje λ nikada neće uvećati test grešku.
(e) Uvećanje λ može uvećati ili smanjiti trening grešku.
(f) Uvećanje λ može uvećati ili smanjiti test grešku.

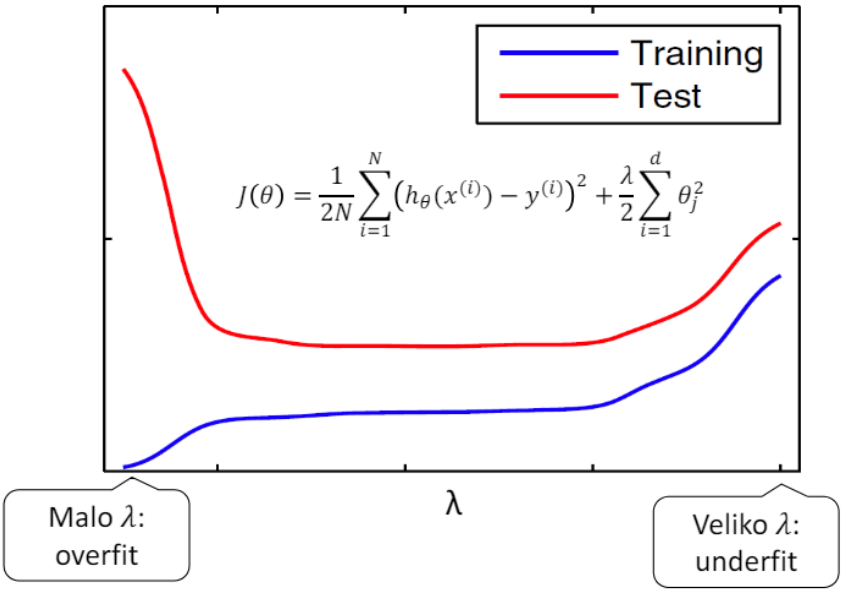
ako ima vec overfittinga smanji ce gresku, ako je model nije vec overfittovan onda ce povecati gresku

8. Da li je potrebno na neki način pripremiti podatke pre regularizacije? Obrazložite odgovor.

Normalizacija podataka jer su ridge i lasso osetljivi na magnitude obelezja. ako su obelezja razlicitih velicina moze dovesto do nepravedne penalizacije

9. Kako biramo optimalnu vrednost λ?
Isprobavanjem i onda sa svakim lambda radimo trainig val test (po potrebi unakrsnu validaciju) i vidimo za koje lambda dobijamo najbolje podatke

10. Na grafiku ispod nacrtajte kako se ponaša greška merena na (a) trening (b) test skupu u zavisnosti od λ.



11. Kojim algoritmom treniramo LASSO model? Opišite ovaj algoritam.

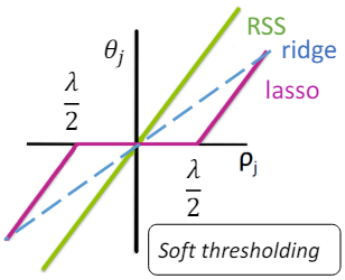
Coordinate descent za lasso

$$\theta_j^{(t+1)} = \begin{cases} \rho_j + \lambda/2 & ako\ je\ \rho_j < \lambda/2 \\ 0 & ako\ \rho_j \epsilon [-\lambda/2, \lambda/2] \\ \rho_j - \lambda/2 & ako\ je\ \rho_j > \lambda/2 \end{cases}$$

Mala korelacija: postavi težinu na 0

Velika (+ ili -) korelacija: Ostavi obeležje u modelu, ali mu smanji težinu za $\lambda/2$

λ definiše šta znači jako/slabo



Soft thresholding

Normalizovana obeležja

Koristimo coordinate descent algoritam, on iterativno optimizuje koeficijente modela tako sto jedan po jedan koeficijent azurira dok ostale fiksira.
Prvo inicijalizujemo pocetne vrednosti koeficijenata onda iteriramo do maxIter koje smo zadali zatim fiksiramo ostale koeficijente osim i tog koeficijenta. Onda azuriramo nas i-ti koeficijent minimizujemo funkciju greske a koristimo i soft thresholding tehniku koja postavlja koeficijent na 0 ukoliko je mala korelacija, u suprotnom ostavlja obelezje u modelu.

Test 4 - Neparametarski modeli

1. Tačno ili netačno:
   a. Ridge radi najbolje kada model sadrži mnogo beskorisnih varijabli.
   b. Ridge radi najbolje kada je većina varijabli u modelu korisna.

2. Šta nam *Elastic Net* regularizacija nudi u odnosu na LASSO i Ridge?

Nudi linearnu kombinaciju lassso i ridge, lasso je dobar u selekciji obelezja kada imamo nerelevantan obelezja, ridge je dobar u interpretaciji kada su sva obelezja relevantna i onda elastic net uzima najbolje od oba

5. Primer NEparametarskog modela za regresiju je Normal Equation, a za klasifikaciju je KNN(ili descision tree ili random forest)
6. Primer parametarskog modela za regresiju je Gradient Descent, a za klasifikaciju SVM
7. Svojim rečima pojasnite razliku parametarskog i neparametarskog pristupa.

Kod parametarskih metoda imamo fiksne parametre teta i nakon njihovog odredjivanja nije nam potreban skup podataka, ali imamo i fiksnu fleksibilnost. Neparametarske metode prilikom predikcije koriste trening skup, pa kolicina podataka za obradu raste sa povecanjem skupa podataka, ali su mnogo fleksibilniji.
Kod parametarskih metoda izbor obelezja je od vece vaznosti nego kod neparametarskih metoda

8. Tačno ili netačno:
   a. Neparametarski modeli se sporo obučavaju.
   b. Neparametarski modeli su robusni na *overfitting*.(diskutabilno sta je granica robusnosti, nisu robusni ali jesu robusniji u odnosu na parametarske modele)
   c. Neparametarski modeli ne zahtevaju puno podataka za obučavanje.
   d. Izbor obeležja je od velikog značaja za performanse parametarskih modela.
   e. Neparametarski modeli uvode veoma slabe pretpostavke o ciljnoj funkciji.
   f. Kod neparametarskih modela nam za predikciju nije potreban skup podataka.
   g. Parametarski modeli imaju ograničenu fleksibilnost.
   h. Neparametarski modeli uvek imaju određeno sistematsko odstupanje.
   i. Parametarski modeli uvek imaju određeno sistematsko odstupanje.
   j. Neparametarski modeli uvode pretpostavke o stvarnoj ciljnoj funkciji *y*.
   k. Parametarski modeli manje pate od prokletstva dimenzionalnosti u odnosu na neparametarske pristupe.

9. Objasnite ideju *Nearest Neighbours* (*local averaging*) pristupa.

Ideja je da se novi podatak klasifikuje /predividi na osnovu slicnosti sa vec postojecim podacima. Racuna se udaljenost izmedju novog podatka i svih ostalih i onda na osnovu metode koju odaberemo racunamo vrednost na osnovu K najblizih ili na osnovu neke raspodele.

10. Pod kojim uslovima 1-NN regresija adekvatno modeluje podatke?

Kada imamo veliki broj podatka i mali sum, tj kada nemamo poroblem sa diskontinuiteto

11. Šta moramo definisati za korišćenje K-NN pristupa?
    - broj suseda
    - meru udaljenosti (funkcija slicnosti)
    - poznate opservacije

12. Kako dajemo predikciju kod K-NN pristupa?

Racunamo udaljenost na osnovu odredjene funkcije izmedjuj novog podatka i vec postojecih podataka, zatim selektujemo k najblizih suseda i na osnovu prosecne vrednosti (i potencijalnih tezinskih faktora) odredjujemo predikciju

13. Koja je prednost K-NN pristupa u odnosu na 1-NN pristup?
Robusniji na sum, nije toliko sklon overfittingu i moze smanjiti efekat izolovanih podataka (mada to je isto sto i ovo prvo)

14. Šta od sledećeg je nedostatak K-NN algoritma?
    a. Niske performanse.
    b. Neosetljivost na *outlier*-e.
    c. Algoritam je računarski zahtevan.
    d. Algoritam ne zahteva mnogo memorije.

13. K-NN spada u:
    a. Reinforcement learning
    b. Nenadgledano obučavanje
    c. Instance-based learning
    d. Lazy learning.

14. Šta od sledećeg je nedostatak *lazy learning*-a?
    a. Teško za održavanje.
    b. Nije primenljivo na širok spektar problema.
    c. Nije pogodno za kompleksne domene.
    d. Nije pogodno za podatke sa velikim šumom.

15. Koji od sledećih algoritama imaju i trening i test fazu:
    a. K-NN
    b. Linearna regresija
    c. Nijedan od navedenih.

16. Šta je od sledećeg tačno za K-NN klasifikator:
    a. Što je trening skup veći, performanse algoritma (tačnost, preciznost,...) su bolje.
    b. Što više obeležja imamo, teže je dobiti dobre performanse.
    c. Najskuplji deo ovog modela je obuka modela.
    d. Možemo koristiti K-NN samo za klasifikaciju.

17. Kako dajemo predikciju u *weighted* K-NN algoritmu? Kako definišemo težine u *weighted* K-NN?

Predikcija u weighted knn:
- racunamo udaljenosti na osnovu predivdjene funkcije
- selektujemo ka najblizih suseda
- svakom susedu dodeljujemo tezinu
- na osnovu suseda i tezina vrsimo predikciju

Tezine definisemo na osnovu udaljenosti od nove tacke, dakle tacke koje se nalaze blize novoj tacki imaju vecu tezinu u odnosu na tacke koje se nalaze dalje

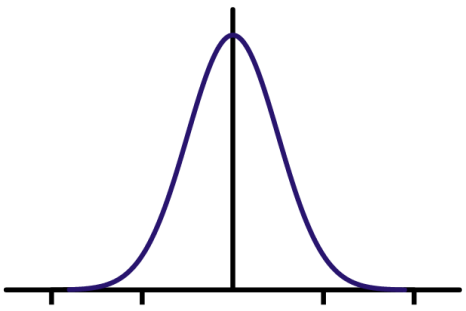
18. Koja je prednost *weighted* K-NN u odnosu na K-NN?

problem sa diskontinuitetom, na primer pomeranjem “prozora” cime iz prozora ispada samo jedna tacka moze da utice mnogo na krajnji rezultat, dok bi se pomocu weighted knn ta tacka svakako nalazila na obodu prozora i time bi imala malu tezinu pa njeno izbacivanje bi imalo neznatan uticaj na promenu rezultata

19. Šta je kernel? Kako se kerneli međusobno razlikuju?

Kernel - funkcija merenja slicnosti izmedju dva podatka, razliciti kerneli se razlikuju po nacinu na koji mere slicnost izmedju podataka sto utice na performanse modela

20. Skicirajte Gausov kernel (obeležite x i y osu na grafiku).



X horizontalno Y vertikalno

21. Koja je razlika kernel regresije i K-NN sa težinskim faktorima?
U kernel regresiji posmatramo sve “komsije” i njihove tezine dok u K-NN sa tezinama posmatramo k “komsija” sa njegovim tezinama.

22. Postoji li kod kernel regresije parametri koji moramo optimizovati?
Sirina kernela i parametar regularizacije.

23. Navedite načine da se borimo sa prokletstvom dimenzionalnosti.
Pridodajemo strukturu nasem modelu, npr najjednostavnija struktura je linearan model. Ovaj model ne pati od prokletstva dimenzionalnosti jer se ne oslanje na lokalna svojstva, nije gotovo nikada tacan ali sluzi kao dobra interpretabilna aproksimacija prave funkcije y

Test 5 - ML estimacija, bijas i varijansa, probabilistička interpretacija regresije

1. Šta je metod maksimalne verodostojnosti (*Maximum Likelihood*, ML)?
   a. Metod estimacije vrednosti parametara koje maksimizuju verovatnoću da bismo opservirali podatke (koje
   zaista jesmo opservirali).
   b. Metod pronalaska podataka koji najverovatnije potiče iz pretpostavljene distribucije.
2. Sakupili smo IID skup podataka $\{x_1, \dots, x_n\}$. Koraci u MLE (ML estimaciji)

   su:

   (1) Definisanje funkcije verovatnoce

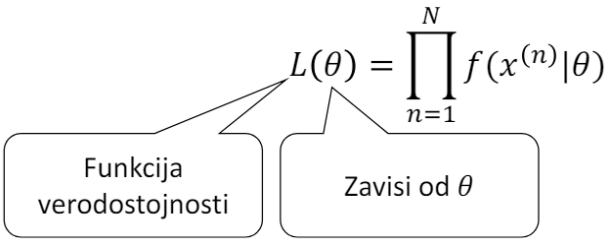
   (2)Maksimizacija log-verovatnoce
3. Pod koja dva uslova možemo reći da je prikupljeni skup podataka

   reprezentativan?

   (1) Svaki element populacije mora da ima jednaku sansu da udje u uzorak

   (2) Uzorak mora da bude dovoljno brojan
4. Intuitivno, šta je verodostojnost?
   a. Verovatnoća opservacije datih podataka.
   b. Verovatnoća opservacije datih podataka, pretpostavljajući određene parametre.
   c. Verovatnoća da je vrednost određenog parametra korektna, ako su dati podaci.
   d. Verovatnoća odabira određenog parametra, ako su dati podaci.
5. Kako je MLE za parametar θ definisan?
   a. To je vrednost θ koja minimizuje verodostojnost opservacije datih podataka
   b. To je vrednost θ koja maksimizuje verodostojnost opservacije datih podataka
   c. To je vrednost θ koja minimizuje negativan logaritam verodostojnosti opservacije datih podataka
   d. To je vrednost θ koja maksimizuje negativan logaritam verodostojnosti opservacije datih podataka
6. Šta znači kada za skup opservacija kažemo da su IID (*Independent and Identically Distributed*)?
   Za tačke izvučene nezavisno jedna od druge iz iste distribucije se kažu da su nezavisne i jednako distribuirane
7. Zaokružite podatke koji su IID.:
   a. Zabeleženi Ishodi uzastopnog bacanja „fer“ novčića (jednake verovatnoće glave i pisma).
   b. Zabeleženi Ishodi uzastopnog bacanja novčića koji nije „fer“.
   c. Naizmenično bacamo dva novčića. Jedan je „fer“, a drugi nije.
   d. Nezavisno uzorkujemo podatke koji dolaze iz distribucije koja je mešavine dve normalne distribucije.
   e. Nasumično anketiramo ljude iz određenog grada da bismo došli do zaključaka o tom gradu.
   f. Nasumično anketiramo ljude iz određenog grada da bismo došli do zaključaka o zemlji u kojoj se grad nalazi.
   g. Imamo kutiju sa numerisanim lopticama. Izvlačimo lopticu iz kutije, beležimo broj i vraćamo je u kutiju. Ponavljamo postupak.
   h. Imamo kutiju sa numerisanim lopticama. Izvlačimo lopticu iz kutije, beležimo broj, ali lopticu ne vraćamo u kutiju. Ponavljamo postupak.
8. Neka je dat skup podataka $\{x_1, \dots, x_n\}$ čiji su elementi IID. Neka elementi potiču iz distribucije $f(x|\theta)$. Kako

računamo verodostojnost skupa podataka $L(\theta)$?



9. (vezano za prethodni zadatak) Kako u praksi pronalazimo θ?
   Maksimizujemo log L(teta), zato sto je logaritam monotono rastuca funkcija a to znaci da je vrednost teta koja maksimizuje ln L(teta) takodje i vrednost koja maksimizuje L(teta). Maksimizacija logaritma je jednaka i minimizaciji negativnog logaritma. A kako je logaritam proizvoda dva broja jednak zbiru logaritama tih brojeva lakse nalazimo izvod. Postoji numericka prednost jer umesto racunanja proizvoda malih brojeva koja moze dovesti do underflowa numericke preciznosti racunamo zbir logaritama tih brojeva.

10. (vezano za prethodni zadatak) Zašto tako?
    Verovatno odgovoreno u 9

11. Koje od sledećih transformacija, kada se primene na verodostojnost, neće promeniti njen maksimum?

    a. Logaritmovanje po bilo kojoj (konstantnoj) bazi
    b. Dodavanje ili oduzimanje vrednosti nezavisne od θ (parametara distribucije)
    c. Primena eksponenta
    d. Množenje pozitivnom konstantom nezavisnom od θ.
    e. Množenje vrednošću koja zavisi od θ.

12. Kako bi se ovakve transformacije (sa osobinama iz prethodnog pitanja) mogle kategorizovati?

    a. Konveksne funkcije
    b. Funkcije koje su pozitivne na celom domenu
    c. Funkcije koje je moguće invertovati
    d. Monotone funkcije
    e. Diferencijabilne funkcije

13. Neka je dat sledeći skup IID podataka: 11.0, 15.2, 18.0, 21.0, 25.8. Pretpostavimo normalnu distribuciju sa srednjom vrednošću μ i standardnom devijacijom σ. Šta je MLE za μ?

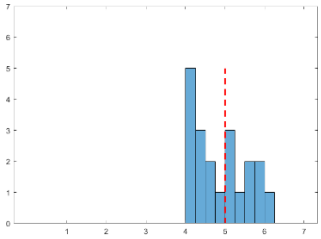
    (a) Manje od 17 (b) Između 17 i 18 (c) Između 18 i 19 (d) Između 19 i 20 (e) Preko 20.

14. Tačno ili netačno:

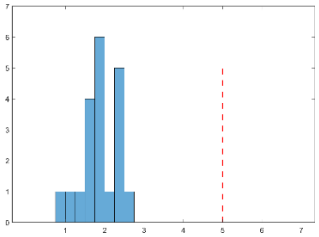
    a. Ako pretpostavimo korektnu distribuciju (koja odgovara podacima), MLE metodom dobićemo tačno onu raspodelu iz koje su generisani podaci.
    b. MLE parametra μ normalne distribucije je nepristrasna ocena
    c. MLE parametra σ normalne distribucije je nepristrasna ocena

15. Za šta mislite da ćemo koristiti ML u okviru mašinskog učenja?
    Za estimaciju parametara modela. Ocena Teta^ je nepristrasna(centrirana) ako vazi E(teta^)=teta. Razlika izmedju E(teta^) i teta je sistematsko odstupanje (bias) ocene teta^. Nepristrasna ocena koja ima manju varijansu je bolja od nepristrasne ocene koja ima vecu varijansu

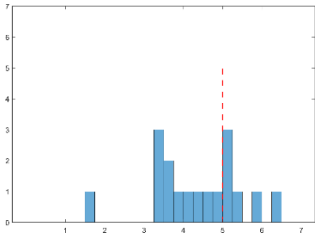
16. Za svaki od sledećih modela recite da li je pristrastan i da li smatrate da je njegova varijansa velika ili mala:



nepristrasan, mala varijansa varijansa



pristrasan mala varijansa



nepristrasan veca

17. Koje pretpostavke smo uveli prilikom fitovanja polinomijalne krive

18.

- Pretpostavka 1: y i x su povezani na sledeći način:

$$y^{(n)} = h_\theta(x^{(n)}) + \varepsilon^{(n)} = \theta^T x^{(n)} + \varepsilon^{(n)}$$

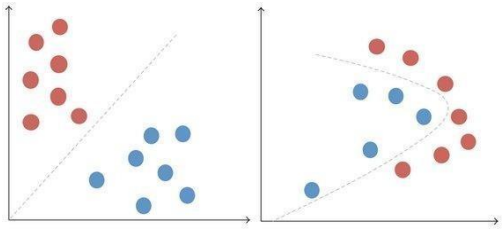
gde ε predstavlja šum

- Pretpostavka 2: $\varepsilon^{(n)}$ su IID po Gausovoj raspodeli sa srednjom vrednošću 0 i nekom varijansom σ^2:

$$\varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$$

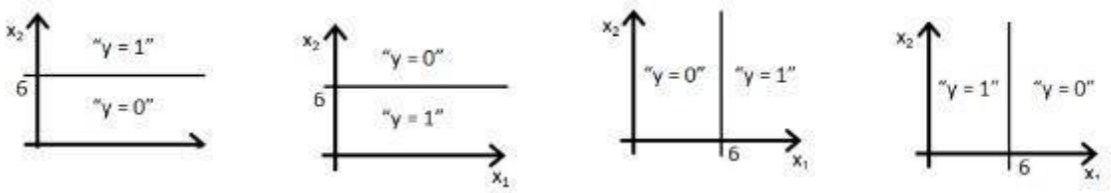
Test 6 - Linearni modeli za klasifikaciju (logistička regresija i perceptron)

1. Logistička regresija koristi se za (1) regresiju (2) klasifikaciju (3) klasterovanje (4) sve navedeno.
2. Logistička regresija kao izlaz vraća verovatnocu. Granica odluke koju proizvodi je linearna/nelinearna (zaokružiti tačno).
3. Koji grafik prikazuje linearnu granicu odluke? Čime je položaj granice odluke određen?



Levi. Odredjen je parametrom teta?????????

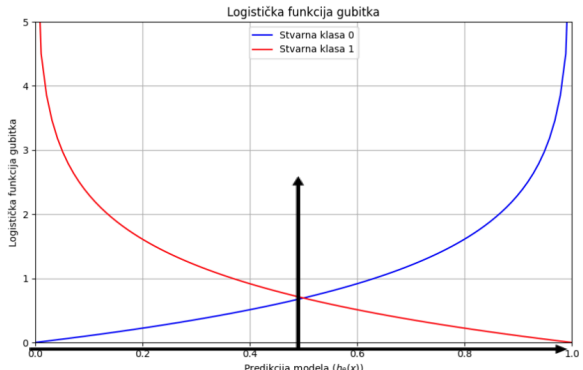
4. Recimo da smo trenirali model logističke regresije $h_\theta = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$ i dobili da je $\theta_0 = 6$, $\theta_1 = 0$, $\theta_2 = -1$. Koji od sledećih grafika predstavlja granicu odluke dobijenog klasifikatora? 2.



5. Kako bi izgledao grafik ako bismo u prethodnom pitanju zamenili vrednosti x_1 i x_2? 4.
6. Zašto se funkcija greške (*cost*) koju smo koristili za linearnu regresiju ne može koristiti kod logističke regresije?

   Kod klasifikacijskih problema, ciljna varijabla je obično binarna (ili možda višeklasna), dok je kod regresije ciljna varijabla kontinuirana. Zbog ove razlike u prirodi ciljne varijable, potrebna je drugačija funkcija greške. Za logističku regresiju, koristimo funkciju greške koja se naziva logistička funkcija gubitka (ili unakrsna entropija). Ova funkcija je dizajnirana da kvantificira razliku između stvarnih klasa i predviđenih klasa, što je suštinski važno za klasifikacijske probleme.

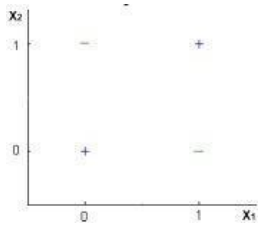
7. Kojim postupkom optimizujemo parametre kod logističke regresije?
   Gradijentni spust, MLE
8. Kako izgleda *cost* funkcija kod logističke regresije? Napišite formulu i Ilustrujte je na grafiku (ne zaboravite da obeležite ose i granice na osama).



$$\text{Cost}(y, \hat{p}) = -[y \log(\hat{p}) + (1 - y) \log(1 - \hat{p})]$$

9. Ako bi kao izlaz modela logističke regresije koristili otežinjenu sumu ulaza (kao u linearnoj regresiji), vrednost izlaza bi se kretala između -besk i +besk, a mi želimo da izlaz bude između 0 i 1.

10. Može li model logističke regresije perfektno klasifikovati podatke na slici ispod? Možete koristiti samo varijable x_1 i x_2.



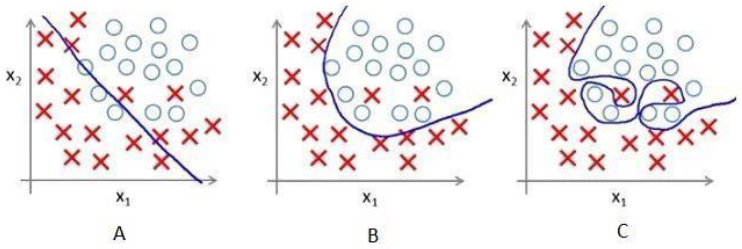
Ne moze dok ne uvedemo 3. dimenziju

11. Tačno ili netačno:

    a. Funkcija greške koju optimizujemo kod logističke regresije je konveksna.
    b. Može nam se desiti da primenom gradijentnog spusta na funkciju greške logističke regresije upadnemo u lokalni optimum. Zato nam je potreban napredniji algoritam za optimizaciju parametara.
    c. Pošto je granica odluke koju proizvodi model logističke regresije linearna, to znači da ne možemo dobiti krivu liniju koja razdvaja klase.
    d. Model logističke regresije (u svojoj osnovnoj formulaciji) možemo primeniti isključivo na problem binarne klasifikacije.
    e. Obavezno moramo normalizovati vrednosti obeležja pre primene modela logističke regresije.
    f. Model logističke regresije može biti *overfit*-ovan.

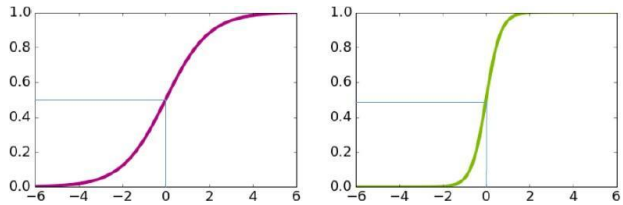
12. Koje metrike ne možemo upotrebiti za evaluaciju modela logističke regresije? (1) accuracy, (2) F-measure, (3) MSE, (4) R^2, (5) precision, (6) recall.

13. Koji od sledećih modela je optimalan, koji *underfit*-ovan, a koji *overfit*-ovan?



UNDERFIT OPTIMALAN OVERFIT

14. U slučaju *overfitting*-a, vrednosti parametara θ će po magnitudi biti veliki (mali/veliki). Ovo znači da će granica odluke biti sličnija grafiku desno(levo/desno). Verovatnoće koje model procenjuje na izlazu biće velike(male/velike).



15. Kako se možemo boriti protiv *overfitting*-a u logističkoj regresiji?

Regularizacijom, penalizovacemo velike koeficijente pa cemo na L(teta) dodati L1 L2 regularizacione penale koji se nece primenjivati na teta0

16. Koji je efekat L1 regularizacije kod logističke regresije?
    Dobijamo na efikasnosti i interpretabilnosti modela jer dolazi do sparse resenja pomocu L1 sto znaci da ce vecina koef biti nula

17. Ako imamo *C* klasa, kod *1-vs-all* pristupa višekategorijskoj klasifikaciji fitujemo C modela, a kod 1-vs-1 pristupa C*(C-1)/2 modela.

18. Kod pojedinačnog modela *1-vs-all* pristupa, vršimo binarnu klasifikaciju da razdvojimo klasu Ck od klase svih osim Ck .

19. Kod pojedinačnog modela *1-vs-1* pristupa, vršimo binarnu klasifikaciju da razdvojimo klasu Ck od klase Ck' .

20. Pristup *1-vs-1* je računarski zahtevniji (zahtevniji/manje zahtevan) u odnosu na *1-vs-all* pristup ako imamo umereno velik skup podataka.

21. U slučaju velikog broja klasa *C*, *1-vs-all* pristup je problematičan jer imamo izuzetno nebalansirane skupove podataka.

22. *Softmax regression* koristimo za visekategorijsku klasifikaciju. Izlaz ovog modela predstavlja vektor ciji su clanovi verovatnoca uspeha za svaku klasu, a kao klasifikacionu odluku biramo klasu sa najvecom verovatnocom uspeha

Test 7 - Linearni modeli za klasifikaciju (NB)

1. Kada biste, u cilju uklanjanja nedostajućih vrednosti, primenili pročišćavanje podataka (uklanjanje obeležja ili opservacija iz skupa podataka)?
   Mali broj nedostajucih vrednosti i veliki broj opservacija. Ukoliko imamo u istom obelezju veliki broj nedostajucih vrednosti onda uklanjanje obelezja u suprotnom uklanjanje opservacija
2. Glavni nedostatak strategije uklanjanja nedostajućih vrednosti je uklanjanjem mozemo ukloniti i znacajne informacije za predikciju.
3. Ukoliko ne želimo da uklonimo nedostajuće vrednosti, možemo ih proceniti. Za kategorijska obeležja tipično koristimo median , a za numerička mean/median. Postoje i naprednije tehnike kao što su regresiona metoda, knn imputacija, EM. Glavni nedostatak ove strategije je moze uzrokovati sistematskom greskom ili dodavanjem sistematskog odstupanja.
4. *Naive Bayes* (NB) model je pogodan za male(male/velike) skupove podataka jer je skloniji da pati od varijanse nego od sistematskog odstupanja(sistematsko odstupanje/varijansa).
5. Tačno ili netačno (iskazi se odnose na NB model):
   a. Sva obeležja su jednako važna.
   b. Obeležja su statistički zavisna jedna od drugih za zadatu klasu.
   c. Obeležja su statistički nezavisna jedna od drugih za zadatu klasu.
   d. Obeležja mogu biti kategorička ili numerička.
6. Formula data Bajesovom teoremom je:

Uslovna verovatnoća — Apriorna verovatnoća

Aposteriorna verovatnoća

$$P(y = c|x) = \frac{P(x|y = c)P(y = c)}{P(x)}$$

Dokaz

7. U formuli, aposteriorna verovatnoća je P(y=c|x), a apriorna P(y=c). Dokaz je P(x).
8. Problem:

   Želimo da odredimo da li pacijent ima određenu formu raka. Znamo da svega 0.8% ljudi na svetu ima ovu formu raka. Postoji test krvi koji nam vraća POS i NEG rezultat. Ako osoba nema rak, dobiće NEG rezultat u 97% slučajeva. Ako osoba ima rak, dobiće POS rezultat u 98% slučajeva.

   Apriorna verovatnoća klase „nema rak“ je 0.992

- Želimo da odredimo da li pacijent ima određenu formu raka. Znamo da svega 0.8% ljudi na svetu ima ovu formu raka. Postoji test krvi koji nam vraća POS i NEG rezultat. Ako osoba nema rak, dobiće NEG rezultat u 97% slučajeva. Ako osoba ima rak, dobiće POS rezultat u 98% slučajeva

$P(\text{cancer}) = 0.008$
$P(\neg\text{cancer}) = 0.992$

Recimo da je osoba dobila rezultat POS na testu krvi. Koja je verovatnoća da ima rak?

$P(\text{NEG}|\neg\text{cancer}) = 0.97$
$P(\text{POS}|\neg\text{cancer}) = 0.03$

$P(\text{POS}|\text{cancer}) = 0.98,$
$P(\text{NEG}|\text{cancer}) = 0.02$

$$P(\text{cancer}|\text{POS}) = \frac{P(\text{POS}|\text{cancer})\text{P}(\text{cancer})}{P(\text{POS})} = \frac{0.98 \cdot 0.008}{0.98 \cdot 0.008 + 0.03 \cdot 0.992} = 0.21$$

9. Kako interpretirate „dokaz“ u Bajesovoj teoremi?

   Verovatnoća da naiđemo na određenu kombinaciju vrednosti obeležja x (bez obzira kojoj klasi pripada)

10. Nastavak na problem iz zadatka 9: Zašto nam je za određivanje $P(cancer|POS)$ potrebna Bajesova teorema? Odnosno, zašto ovu verovatnoću procenjujemo primenom formule $P(\text{cancer}|\text{POS}) = \frac{P(\text{POS}|\text{cancer})\text{P}(\text{cancer})}{P(\text{POS})}$, a ne procenjujemo $P(cancer|POS)$ direktno iz skupa podataka?

    Nemamo direktne podatke ili dovoljan broj uzoraka koji bi nam odmogucili da procenimo ovu verovatnocu iz skupa podataka

11. Zašto se NB klasifikator zove „naivan“?

    uvodimo pretpostavku da su sva obelezja medjusobno nezavisna, sa obzirom na ciljnu varijablu

- **Naivni** Bajes:
  - uvešćemo pretpostavku da su obeležja skupa podataka uslovno nezavisna za zadatu klasu:

$$P(x|y) = \prod_{d=1}^{D} P(x_d|y)$$

Specifičan model za obeležje *d*

12. Zašto uvodimo „naivnu“ pretpostavku?

    Zato sto ona dovodi do velike redukcije broja nezavisnih parametara koje moramo estimirati

13. Kada računamo verovatnoću $P(x_d|y = c) = \frac{N_{x_d c}}{N_c}$ u NB modelu, na koju grešku možemo naići i kako je možemo rešiti?

    Mozemo naici na gresku da odustvo jedne vrednosti jednog atributa cini da ceo slog ima veorvatnocu nula i to resavamo pomocu smoothinga

    moze doci do toga da u podacima nemamo vrednost (xd, y=c), i u tom slucaju Nxd,c ce biti 0. Tomozemo da resimo pomocu smoothinga.

- Kako bismo izbegli verovatnoće 0 usled nedostatka reprezentat primera, dodaćemo *smoothing term* u multinominalni NB:

$$P(x_d|y=c) = \frac{N_{x_d,c} + \alpha}{N_c + \alpha V}$$

α – *parameter for additive smoothing*

V – broj mogućih vrednosti obeležja d

- Dodavanje αV „fiktivnih" primera jednako raspoređenih po svi mogućim vrednostima obeležja x_d
- $\alpha < 1 \rightarrow$ Lidstone smoothing
- $\alpha = 1 \rightarrow$ Laplace smoothing

14. Dva načina da primenimo NB u slučaju kontinualnih obeležja su podelom na intervale i gausovim kernelom.
15. Tačno ili netačno:
    a. NB je generativni model.
    b. NB je robustan na irelevantna obeležja.
    c. NB ima dobre performanse, čak i kada je narušena pretpostavka o uslovnoj nezavisnosti obeležja date klase.
    d. Logistička regresija je generativni model.
    e. NB je nelinearni klasifikator.
    f. Generativni modeli direktno uče $P(y|x)$.
    g. Generativni modeli uvode slabije pretpostavke o podacima od diskriminativnih modela.
    h. Generativnim modelima treba manje podataka za trening od diskriminativnih modela.???
    i. Generativni modeli mogu da rade sa nedostajućim vrednostima, a diskriminativni ne.
    j. Obučenim generativnim modelom možemo generisati primere skupa podataka.
16. Koju pretpostavku uvodimo kod NB sa Gausovim kernelom? Kako se obezbeđujemo da je ispoštovana?
    Uvodimo pretpostavku da su kontinualna obeležja u svakoj klasi distribuirana prema normalnoj (Gausovoj) distribuciji.

- Pretpostavka: x_d prati normalnu (Gausovu) raspodelu:

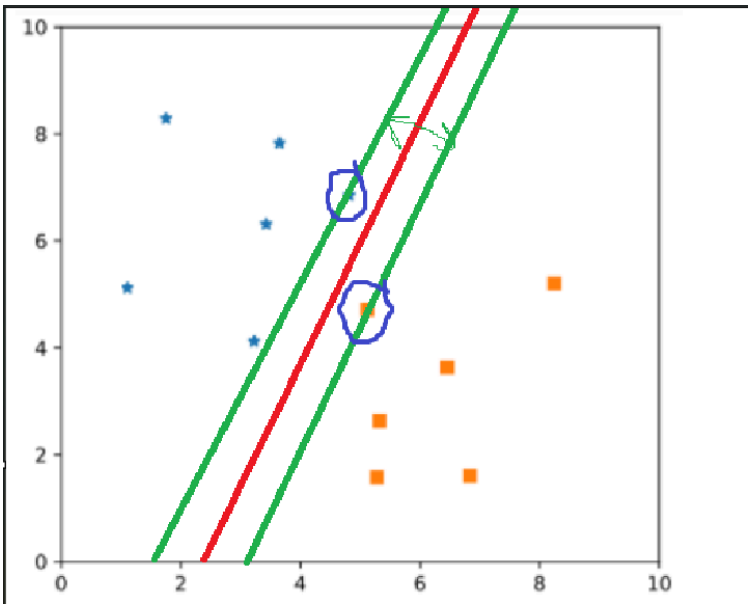
$$P(x_d|y=c) = \frac{1}{\sqrt{2\pi\sigma_{d,c}^2}} \exp\left\{-\frac{(x_d - \mu_{d,c})^2}{2\sigma_{d,c}^2}\right\}$$

$$P(x|y=c) = \prod_{d=1}^{D} P(x_d|y=c)$$

Test 8 - SVM

1. U SVM (*Support Vector Machine*) algoritmu, dimenzija rezultujuće hiper-ravni zavisi od:
   a. broja obeležja
   b. broja primera u skupu podataka
   c. broja vrednosti koje uzima ciljna varijabla
   d. svega navedenog.

2. Na slici ispod ilustrujte kako izgleda granica odluke za SVM model. Označite na ovoj slici vektore potpore (*support vectors*) i marginu hiper-ravni.



3. Tačno ili netačno:

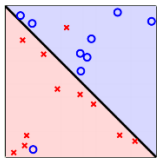
   a. U svojoj osnovnoj formulaciji, SVM je primenljiv na probleme višekategorijske klasifikacije.
   b. Brisanje (uklanjanje) vektora potpore promeniće poziciju hiper-ravni.
   c. Uklanjanje korektno klasifikovane instance iz skupa podataka koja se nalazi daleko od granice odluke promeniće poziciju hiper-ravni.

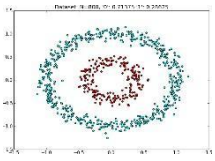
4. Šta su *linearno separabilni* podaci?

Linearno separabilni podaci su oni podaci koji se mogu tačno razdvojiti ravnom linijom (u slučaju dvodimenzionalnog prostora) ili hiper-ravni (u višedimenzionalnom prostoru) na način da se svi primeri jedne klase nalaze sa jedne strane linije/hiper-ravni, a svi primeri druge klase sa druge strane.

5. Kako možemo primeniti SVM model u slučaju kada podaci NISU linearno separabilni? Za slike ispod označite koji pristup bi bio bolji za taj tip podataka.

SOFT MARGINS KERNEL TRIK





6. U SVM algoritmu se funkcija koju optimizujemo u cilju pronalaska optimalne hiper-ravni zove:

   a. Categorical cross-entropy loss
   b. Binary cross-entropy loss

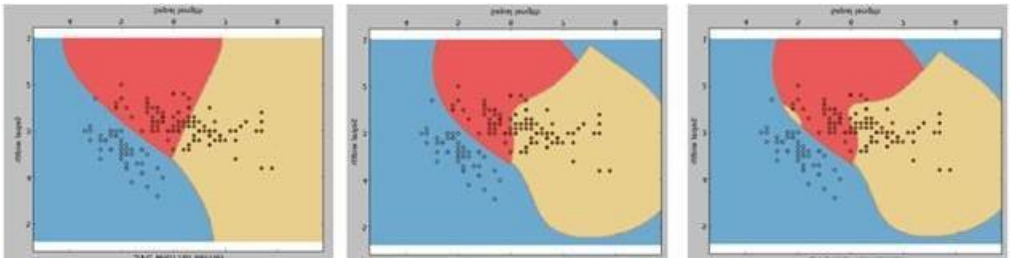
c. Hinge loss
d. Nijedna od navedenih.

Ilustrujte kako izgleda ova funkcija na grafiku.

7. Efektivnost SVM klasifikatora zavisi od:
   a. Selekcije kernela
   b. Parametara kernela
   c. Soft margine parametra C
   d. Svega navedenog.

8. Recimo da smo iscrtavali vizuelizaciju za različite vrednosti parametra C (*slack penalty*) u *soft margin SVM*: $\min \frac{1}{2}\theta^T\theta + C \cdot (\text{br. grešaka})$. Ako C1 odgovara prvom grafiku, C2 drugom, a C3 trećem, šta je tačno od sledećeg:

   a. C1 = C2 = C3; b. C1> C2 > C3; c. C1 < C2 < C3; d. Ne možemo reći.

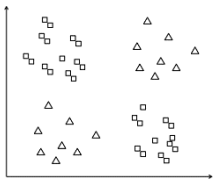


c

9. Objasnite uticaj parametra C kod *soft margine* SVM: $\min \frac{1}{2}\theta^T\theta + C \cdot (\text{br. grešaka})$. Šta se dešava sa marginom kada je $C = 0$ i kada je $C = \infty$? Kako u praksi biramo optimalnu vrednost C?

Kada je C=0 onda ignorisemo greske ne penalizujemo nista pa dolazi do underfittinga
Kada je C= besk onda svaka greska ima veliku cenu pa dolazi do overfittinga
Unakrsna validacija ili koriscenje posebnog validacionog skupa

10. Za date primere (kvadrati su jedna klasa, a trouglovi druga), koji od sledećih kernela bismo mogli iskoristiti da razdvojimo dve klase:



   a. Linearni kernel
   b. *Gaussian* RBF kernel
   c. Polinomijalni kernel
   d. Nijedan od navedenih.

11. Možemo li primeniti SVM na problem višekategorijske klasifikacije? Ako da, na koji način?

Strategijama za kombinovanje binarnih klasifikatora 1vs1 ili 1vsAll

12. Dat vam je binarni klasifikacioni problem gde je broj primera u skupu podataka N manji od broja obeležja D. Ako biste primenjivali SVM nad ovim skupom podataka, koji od sledećih kernela će najverovatnije biti odgovarajući:
    a) linearni; b) polinomijalni; c) RBF;

13. Recimo da imamo skup podataka sa D=10 obeležja i N=5000 primera. Nakon što smo trenirali model logističke regresije, vidimo da su i trening i validaciona greška visoke. Koji od sledećih koraka deluju da će rezultovati boljim performansama:

   a. Uvećati regularizacioni parametar λ
   b. Trenirati SVM model sa RBF kernelom
   c. Kreirati nova polinomijalna obeležja
   d. Trenirati SVM model sa linearnim kernelom
   e. Smanjiti broj primera u skupu podataka

14. Šta je „kernel trik“?

Kernel trik je tehnika koja omogućava da linearni klasifikatori, kao što je SVM, efikasno rade u visokodimenzionalnim ili nelinearnim prostorima bez eksplicitnog transformisanja podataka u te prostore. To se postiže korišćenjem funkcija kernela, koje izračunavaju sličnost između parova podataka u originalnom prostoru, ali kao da su transformisani u viši dimenzionalni prostor.

15. Razmotrite sledeća dva primera (tačke u 2D): $A = (1, 2)$, $B = (2,4)$. Iskoristite sledeće mapiranje u 6-dimenzioni prostor: $\Phi(x) = (x_1^2, x_2^2, \sqrt{2}x_1x_2, \sqrt{2}x_1, \sqrt{2}x_2, 1)$:

a) $\Phi(A) = (1, 4, 2\sqrt{2}, \sqrt{2}, 2\sqrt{2}, 1)$

b) $\Phi(B) = (4, 16, 8\sqrt{2}, 2\sqrt{2}, 4\sqrt{2}, 1)$

Sada izračunajte skalarni proizvod ovde dve tačke:

c) $\Phi(\mathrm{A})^T\Phi(B) = 4 + 64 + 32 + 4 + 16 + 1 = 121$

Kernel funkcija koja odgovara transformaciji datoj iznad je polinomijalni kernel drugog stepena: $K(x, y) = (x^T y + 1)^2$. Iskoristite ovu funkciju da izračunate:

d) $K(A, B) = (2 + 8 + 1)\text{^}2 = 121$

Zakljucak: poenta kernela je da se mnogo brze dodje do istog rezultata do kojeg bi stigao i sa transformacijama

Test 9 - Ansambli

1. Koja je osnovna ideja iza ansambl modela zajednicka za sve postupke
   Osnovna ideja je kombinovanje vise predikcija pojedinacnih modela kako bi se dobile bolje performanse nego sto bi postigli pojedinacni modeli
2. Navedite neke načine kombinovanja glasova različitih modela (za regresiju i klasifikaciju).
   Za klasifikaciju:majority voting,weighted voting,soft voting
   Za regresiju: averaging, weightet averaging,median ,stacking

3. Navedite barem 4 pristupa kojima nad istim skupom podataka možemo obučiti različite modele.
   - manipulacija obucavajuceg algoritma (na istim podacima trenirati razl modele nezavisno ili iste modele sa razlicitim param)
   - manipulacija trenig skupom(napraviti vise razlcitih trening skupova uzorkovanjem
   - manipulacija skupa obelezja(isti podaci razliciti podskupovi obelezja)
   - manipulacija klasnih oznaka
4. Objasnite osnovnu ideju *Bagging*-a.
   Osnovna ideja bagginga (bootstrap aggregating) je tehnika koja se koristi za poboljšanje stabilnosti i tačnosti modela putem kombinovanja više instanci istog osnovnog algoritma, ali treniranih na različitim podskupovima trening podataka. Ova tehnika je posebno korisna za smanjenje varijanse modela koji su skloni preprilagođavanju (overfitting). Sastoji se od nasumicnog uzorkovanja sa ponavljanjem, treninga nekoliko modela na razlicitim podskupovima i kombinovanja predikcije.

5. Koje hiper-parametre ima *Bagging* algoritam?
   Broj estimatora, velicita bootstrap uzorka i broj obelezja
6. Koji je najpopularniji predstavnik *Bagging* algoritma? Koji osnovni model se koristi u okviru ovog ansambl modela?
   Najpopularniji algoritam je rangom forest, a osnovni model koji se koristi u okviru ovog ansambl modela je stablo odlucivanja

7. Objasnite osnovnu ideju *Boosting* algoritma.
   Osnovna ideja Boosting algoritma je da se kombinovanjem više slabih modela stvori moćan ansambl model koji je sposoban za preciznije predviđanje. Glavna svrha Boosting-a je da se iterativno poboljšava tačnost ansambla fokusirajući se na greške koje prethodni modeli prave.

8. Šta to „učimo“ u okviru *boosting* algoritma (koje parametre)?
   Ucimo tezine klasifikatora i tezine primera

9. Kako prinuditi članove ansambla da se prilagode različitim delovima ulaznog prostora?
   Svaki sledeci clan ce biti fokusiran da podatke na kojima je prethodni model gresio

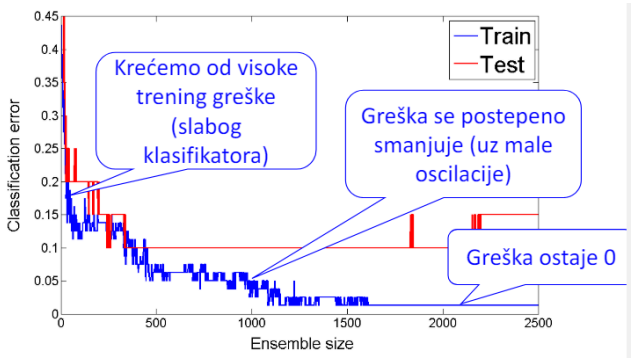
10. Kako u okviru *boosting* algoritma biramo „teške” primere?
    Tezi primeri imaju vecu verovatnocu selekcije i mogu biti selektovani vise puta. Teski primeri se izdvajaju prolaskom kroz modele, ako neki model ne uspe da tacno resi primer njegova tezina(ujedno i verovatnoca za pojavljivanje u sledecem modelu) se povecava
11. Kako učimo na otežinjenim podacima (Kako nateramo klasifikator da se “fokusira” na teže primere)?
    Mislim da je opsiano u prethodnom primeru?

13. U *boosting*-u, klasifikatori koji jako greše će dobiti malu težinu, klasifikatori koji malo greše će dobiti veliku težinu, a klasifikatori slični nasumičnom klasifikatoru će dobiti težinu koja je mala . (veliko/malo)

14. U *boosting*-u, ako klasifikator u *k*-toj iteraciji ima malu grešku, težine instanci α_i koje je taj klasifikator dobro klasifikovao će opadati, a težine instanci koje je klasifikator loše klasifikovao će rasti(rasti/opadati/nijedno).

15. U *boosting*-u, ako klasifikator u *k*-toj iteraciji ima grešku sličnu nasumičnom klasifikatoru, težine instanci α_i koje je klasifikator dobro klasifikovao će nijedno, a težine instanci koje je klasifikator loše klasifikovao će nijedno(rasti/opadati/nijedno).

16. Nacrtajte na sledećem grafiku kako se ponašaju greška na trening i test skupu kod *AdaBoost* algoritma.



17. Tačno ili netačno:
    a. Kao osnovni model u *bagging* algoritmu je dobro koristiti fleksibilan model sklon *overfitting*-u.
    b. Kao osnovni model u *boosting* algoritmu je dobro koristiti fleksibilan model sklon *overfitting*-u.
    c. *Bagging* je sekvencijalni model (treniranje k-tog modela zavisi od rezultata (*k*-1)-og modela).
    d. *Boosting* je sekvencijalni model (treniranje k-tog modela zavisi od rezultata (*k*-1)-og modela).
    e. U *bagging*-u svi modeli imaju jednaku težinu glasa.
    f. U *boosting*-u svi modeli imaju jednaku težinu glasa.
    g. Treniranje *boosting* modela je računski efikasnije od treniranja *bagging* modela.
    h. *Bagging* i *boosting* modeli su manje skloni *overfitting*-u u odnosu na modele koji nisu modeli ansambla.
    i. Nije moguće *overfit*-ovati *bagging* model.
    j. Nije moguće *overfit*-ovati *boosting* model.
    k. *AdaBoost* algoritam je otporan na *outlier*-e.
    l. *AdaBoost* je dizajniran za binarnu klasifikaciju, ali se može koristiti za višekategorijske klasifikacione probleme.

18. *Bagging* redukuje varijansu, a boosting sistematsko odstupanje i varijansu osnovnog modela (sistematsko odstupanje/varijansu).

19. Opišite *stacking* algoritam.

Stacking (ili stacked generalization) je tehnika ansambliranja koja kombinuje predikcije više različitih modela kako bi se dobila bolja predikcija. Osnovna ideja iza stacking-a je da se koristi više različitih modela za predviđanje ciljne promenljive, a zatim se koristi još jedan model (metamodel ili metalearner) koji uči kako kombinovati predikcije tih osnovnih modela.

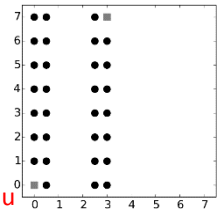
20. Koja dva uslova treba da ispunjava ansambl klasifikatora kako bi imao veće performanse od svojih individualnih članova?
    Klasifikatori moraju biti tacni i klasifikatori moraju biti medjusobno razliciti

Test 10 - Klasterovanje

1. Koji od sledećih problema možemo rešiti klasterovanjem?
   a. Predikcija količine kišnih padavina bazirano na relevantnim obeležjima
   b. Obučavanje robota da prođe labirint
   c. Ispitivanje velike kolekcije *spam* poruka u cilju otkrivanja pod-tipova *spam*-a
   d. Dati su podaci o dečijoj visini i godinama. Predvideti visinu deteta u zavisnosti od njegove starosti.
   e. Data je kolekcija od 1000 eseja na temu ekonomije. Automatski grupisati slične eseje.
   f. Dato je 50 članaka napisanih od strane ženskih autora i 50 članaka napisanih od strane muških autora. Obučiti algoritam da određuje pol autora na osnovu teksta.

2. Tačno ili netačno – *K-means* algoritam:
   a. Zahteva da broj obeležja bude manji ili jednak broju primera
   b. Nema garanciju konvergencije
   c. Konvergira u lokalni optimum
   d. Uvek konvergira u globalni optimum
   e. Rezultati *K-means* algoritma veoma zavise on inicijalizacije centroida
   f. Rezultuje najmanjom vrednošću ciljne funkcije kada je K=1
   g. Konvergira u globalni optimum isključivo ako se inicijalni centroidi poklapaju sa nekim od instanci skupa podataka.

3. Dati su 2D podaci na slici. Ako su dve tačke označene kvadratima inicijalni centroidi, nacrtajte klastere nakon jedne iteracije *K-means* algoritma. Da li se rešenje izmeni nakon druge iteracije??????



4. Opišite *K-means* algoritam:
   K-means algoritam je iterativni metod za klasterovanje podataka. Počinje slučajnim izborom K tačaka kao početnih centroida klastera. Zatim se svaka tačka podataka dodeljuje najbližem centroidu formirajući K klastera. Centroidi se zatim pomeraju tako da se minimizuje suma kvadrata udaljenosti svih tačaka od njih. Postupak se ponavlja dok se centroidi ne stabilizuju ili se dostigne maksimalni broj iteracija.

5. Da li je neophodno pretprocesirati obeležja skupa podataka pre primene *K-means* algoritma ako upotrebljavamo Euklidsku distancu? Ako da, koja vrsta pretprocesiranja je potrebna?
   Da, neophodno je uraditi normalizaciju podataka zbog razlicitih raspona velicina razlicitih obelezja koja mogu da uticu na resenja

6. Koji od sledećih algoritama je deterministički (ishodi se ne menjaju ponovnim pokretanjem algoritma):
   a. PCA; b. *K-means*; c. Nijedan od navedenih

7. Svrha *K-means++* algoritma je da predupredi problem zavisnosti resenja od pocetne inicijalizacije. Alternativa je da primenimo sledeći postupak:da pokrenemo kmeans odredjen broj puta i uzmemo minimum funkcije u tih n pokretanja.

8. U *K-means* algoritmu model klastera definišemo putem centroida. Posledica ovoga je da rezultujući klasteri imaju sferni oblik.

9. Opišite *K-means++* algoritam. Ovaj algoritam nam garantuje/ne garantuje da ćemo pronaći globalni optimum (zaokružiti).

   Poboljsana verzija kmeans algoritma pomaze u boljoj konvergenciji ka globalnom optimumu i smanjuje verovatnocu da algoritam zapadne u lokalni optimum. Prvo se inicijalizuje prvi centroid, nakon toga sledeci centri se biraju koristeci verovatnocu proporcionalnu kvadratu udaljenosti od najblizeg centra koji je vec odabran. Tj sto je tacka udaljenija od centra to je veca verovatnoca da ce biti odabrana kao sledeci centroid.

Proces dodavanja centara se ponavlja dok se ne izaberu svih K centara ovaj postupak doprinosi ravnomernom rasporedu centara i smanjivanjem verovatnoce da zapadne u lokalni optimum

10. Funkcija koju minimizujemo kod *K-means* algoritma je sledeća (opišite je rečima ili formulom sa označenim simbolima):

$J = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \mu_i\|^2$

Gde su:

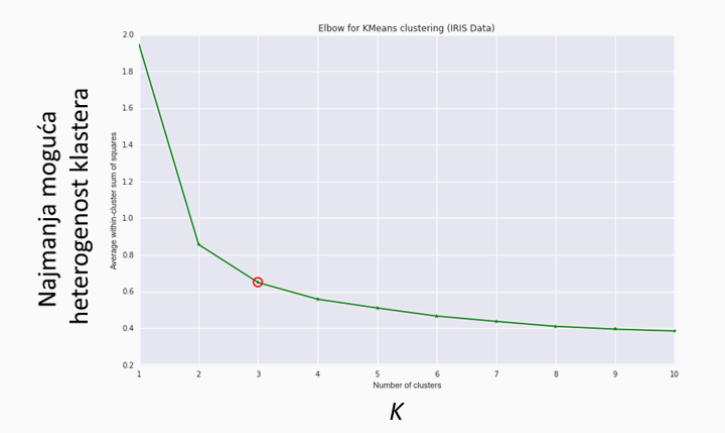
- k broj klastera.
- C_i skup podataka koji pripadaju klasteru i.
- x podatak iz skupa C_i.
- μ_i centroid klastera C_i.
- $\|x - \mu_i\|^2$ kvadrat Euklidske udaljenosti između podatka x i centroida μ_i.

11. Ako uvećavamo broj klastera *K*, vrednost ciljne funkcije iz zadatka 10 se smanjuje/uvećava. Zato možemo/ne možemo koristiti vrednost ove ciljne funkcije da odredimo optimalan broj klastera (zaokružite tačno).

12. Recimo da ste izvršili *K-means* algoritam i dobili da je ciljna funkcija (zadatak 10) za jedno pokretanje K-*means* mnogo veća za *K*=5 nego za *K*=3. Zaokružite jednu opciju:

    a. Ovo nije moguće – mora da postoji greška u kodu
    b. Na osnovu rezultata, zaključujem da je optimalan broj klastera *K*=3
    c. U slučaju *K*=5, *K-means* je završio u lošem lokalnom minimumu. Treba ponovo da pokrenem *K-means* (više nasumičnih inicijalizacija)
    d. U slučaju *K*=3 je pokretanje bilo slučajno srećno. Treba da isprobam različite nasumične inicijalizacije za *K*=3 sve dok performanse za *K*=3 ne budu iste ili gore od slučaja *K*=5.

13. Kod *K-means* klasterovanja se metod „lakta na krivoj" (*elbow method*) primenjuje radi odredjivanja K. Ilustrujte kako bi izgledao rezultujući grafik i obeležite njegove ose. Tekstom opišite kako se dobija svaka tačka na grafiku.

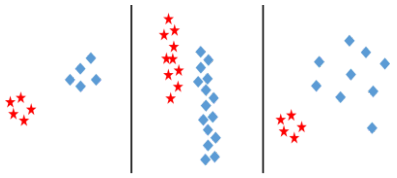


14. Pored računarske zahtevnosti, nedostatak *elbow* metode u praksi je da se nekad laktovi ne vide i tesko se pronalaze.

15. Kako evaluiramo rezultat klasterovanja? Objasnite na primeru klasterovanja tekstualnih dokumenata po temi.

- euklidska udaljenost (moze biti sa tezinama svakog obelezja)
- kosinusna udaljenost je veoma efikasna kada imamo sparse vektore
- kosinusna udaljenost ne zavisi od duzine dokumenta nego samo od sadrzaja
- normalizacija rezultuje time da objekti razlicite duzine budu slicniji, kompromis je ograniciti maksimalnu i minimalnu duzinu dokumenta

16. Za slučajeve prikazane na slici označite koji algoritmi (od *K-means* bez otežinjenih dimenzija i GMM) su mogli rezultovati dobijenim klasterima.



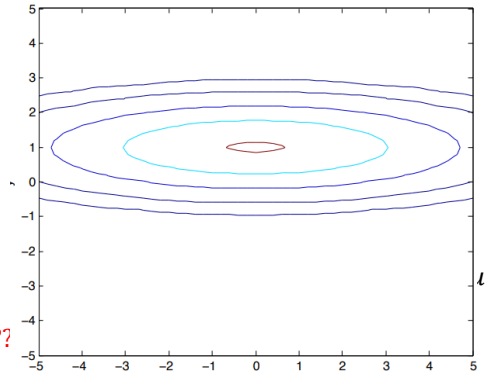
1. oba
2. gmm
3. gmm

17. Tačno ili netačno:
    a. Može se desiti da EM algoritam postavi varijanse klastera na 0.
    b. *K-means* se često zaglavljuje u lokalnom optimumu, dok ovo nije veliki problem za EM.
    c. GMM bolje modeluje klastere različitih veličina i orijentacija u odnosu na *K-means*.
    d. GMM bolje modeluje klastere koji se preklapaju od *K-means.*
    e. EM je manje podložan overfitting-u od *K-means*.
    f. *K-means* je identičan GMM modelu gde smo dijagonalne komponente u matrici kovarijanse postavili na vrednosti bliske 0.
    g. GMM model je nenadgledan.
    h. GMM model svaku instancu skupa podataka pridružuje isključivo jednom klasteru.

18. Koje su prednosti GMM (*Gaussian Mixture Model*) algoritma nad *K-means* algoritmom?

fleksibilniji i ima deskriptivniji izlaz. Moze da modeluje razlicite velicine i oblike klastera, verovatnoca pripadnosti i da je manje podlozan lokalnim optimumima

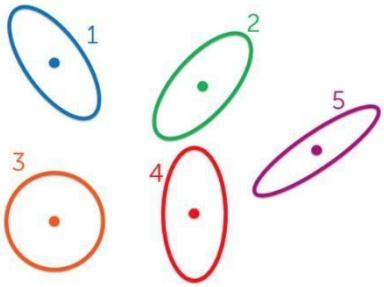
19. Šta su μ i Σ Gausove distribucije prikazane na grafiku?



???????

a. $\mu = [0,0]^T, \Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$
b. $\mu = [0,1]^T, \Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$
c. $\mu = [0,1]^T, \Sigma = \begin{bmatrix} 4 & 0 \\ 0 & 0.25 \end{bmatrix}$

$\mu = [0,1]^T, \Sigma = \begin{bmatrix} 4 & 1 \\ 1 & 0.25 \end{bmatrix}$



20. Recimo da imamo podatke opisane sa 3 obeležja. Postavimo broj klastera na 4 i koristimo pune matrice kovarijanse. Koliko parametara imamo u GMM modelu? Objasnite.
- srednje vrednosti 3 obelezja u 4 klaster 3x4=12
- kovarijacione matrice 3x3 dimenzije i svaka u sebi ima (3x3)/2=6 param pa za 4 klaster 4x6=24
- verovatnoca pojavljivanja klastera Pi za 4 klastera imamo 3 param jer su verovatnoce normalizovane pa je pposlenji parametar odredjen uslovom normalizacije dakle 3
- 12+24+3=39

21. Recimo da imamo podatke opisane sa 4 obeležja. Postavimo broj klastera na 5 i pretpostavimo dijagonalne matrice kovarijanse.
    Koliko parametara imamo u GMM modelu? Objasnite.
    - srednje vrednosti 20
    - dijagonalne matrica imaju 1 param za svaku deimnziju dakle 4 param po klasteru i 5 klastera = 20
    - 4
    - 20+20+4=44

22. Koje od kontura na slici kod zadatka 19 opisuju GMM sa matricom kovarijanse koja ima ne-nula elemente samo na glavnoj dijagonali?
    Diag , to su slike 3 i 4
23. Šta su u EM (*Expectation-Maximization*) algoritmu E i M koraci?
    a. E – proceniti verodostojnost preko parametara klastera, M – Maksimizovati odgovornosti klastera
    b. E – proceniti odgovornost klastera, M – maksimizovati verodostojnost preko parametara klastera
    c. E – proceniti verodostojnost preko parametara klastera, M – Maksimizovati broj parametara klastera
    d. E – proceniti broj parametara, M – maksimizovati verodostojnost preko parametara klastera.
24. Uopštenije, E i M koraci su:
    a. E – proceniti nedostajuće/latentne varijable skupa podataka; M – maksimizovati verodostojnost preko parametara modela
    b. E – proceniti broj nedostajućih/latentnih varijabli skupa podataka; M – maksimizovati verodostojnost preko parametara modela
    c. E – proceniti verodostojnost preko parametara modela; M – maksimizovati broj nedostajućih/latentnih varijabli u skupu podataka
    d. E – proceniti verodostojnost preko parametara modela; M – maksimizovati broj parametara modela

25. Pretpostavimo da podaci dolaze iz 6 Gausijana (ovo je stvarna struktura podataka). Za koji model, čiji su parametri određeni EM
    algoritmom, očekujete da će imati najveću verodostojnost:

    a. Mešavina 2 Gausijana; b. Mešavina 6 Gausijana; c. Mešavina 8 Gausijana; d. Mešavina 10 Gausijana.

Test 11 - Redukcija dimenzionalnosti (PCA)

1. Navedite dva pristupa smanjenju broja obeležja. Po čemu se ovi pristupi razlikuju (iz perspektive rezultujućeg smanjenog skupa obeležja)?

   izbacicemo irelevantna obelezja.

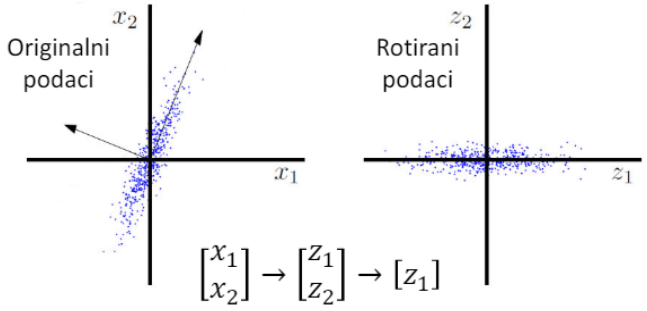
   kompesovacemo vise obelezja nekom linearnom transformacijom.

   razlika je u tome sto prvo resenje zadrzava originalna obelezja, dok drugo kreira nova, transformisana obelezja i tu nema odbacivanja

2. PCA je tehnika za smanjenje dimenzionalnosti.

3. Objasnite i skicirajte osnovnu ideju PCA (ne zaboravite da označite ose na graficima).

Principal Component Analysis (PCA) je metoda za smanjenje dimenzionalnosti podataka koja identifikuje glavne komponente u podacima. Glavne komponente su linearne kombinacije originalnih obeležja koje maksimalno objašnjavaju varijansu u podacima. Metod se sastoji iz standardizacije podataka, izracunavanja kovarijacione matrice, izracunavanje sopstvenih vrednosti i kovarijacione matrice, zatim sortiranje tih vektora, odabira komponenti i transformacije podataka



4. U kakvom su odnosu obeležja koja proizvede PCA algoritam sa originalnim obeležjima?

Obeležja koja proizvede PCA algoritam su linearne kombinacije originalnih obeležja.

5. Ako je p_1 prva glavna komponenta, a p_2 druga, koji od sledećih iskaza su tačni:
   1) Varijansa po p_2 je veća od varijanse po p_1.
   2) p_1 je normalna na p_2.
   3) p_1 je paralelna sa p_2.
   4) Varijansa po p_1 je veća od varijanse po p_2.

6. Da li je potrebno pretprocesirati skup podataka pre primene PCA? Ako jeste, napišite kako i zbog čega.

podaci moraju da budu centrirani i opcionalno normalizovani. Bitno je da budu centrirani jer se pca zasnima na pronalazenju pravaca koji maksimalno objasnjavaju varijansu podataka

Šta je pravilan postupak za normalizaciju obeležja (1, 2 ili svejedno):

1) Prvo, za svako obeležje d odredimo srednju vrednost μ_d i standardnu devijaciju σ_d. Normalizujemo sva obeležja primenom formule $x_d = \frac{(x_d - \mu_d)}{\sigma_d}$. Nakon toga, podelimo skup podataka na trening i test skup. Treniramo model na trening skupu, a potom ga evaluiramo na test skupu.

2) Podelimo skup podataka na trening i test skup. Za svako obeležje, koristeći isključivo trening skup, odredimo srednju vrednost srednju vrednost μ_d i standardnu devijaciju σ_d. Potom, normalizujemo sva obeležja trening skupa i sva obeležja test skupa primenom iste formule $x_d = \frac{(x_d - \mu_d)}{\sigma_d}$. . Treniramo model na trening skupu, a potom ga evaluiramo na test skupu.

7. Obrazložite svoj odgovor.

2. je tacno jer ce pod 1. procuriti informacije o test skupu na trening skup

8. PCA je nadgledana/nenadgledana metoda (zaokružite tačno).

9. Kako odabrati K (novi broj dimenzija) kod PCA metode?

   1) Ako je cilj vizuelizacija:
   K = 2 ili K = 3

   2) Ako je cilj da ubrzamo izvršavanje algoritma (uz izbegavanje prevelikog gubitka u performansama):

   90%,95%,99% procenat varijanse koju zelis da zadrzis

10. Da li se PCA može primeniti za prevenciju overfittinga?
    moze jer smanjuje dimenzionalnost i eliminise sum, ali je bolje koristiti druge metode

11. PCA radi bolje ako: (1) postoji linearna struktura u podacima, (2) podaci leže na zakrivljenoj površini, a ne na ravnoj, (3) obeležja su skalirana na iste opsege:
    1) Važe (1) i (2)
    2) Važe (2) i (3)
    3) Važe (1) i (3)
    4) Važe (1), (2) i (3).

12. Tačno ili netačno:
    1) PCA je podložan upadanju u lokalni optimum. Ispitivanje više nasumičnih inicijalizacija može da pomogne.
    2) PCA je deterministički algoritam.
    3) Sve glavne komponente dobijene pomoću PCA su međusobno ortogonalne.
    4) Čak i ako se ulazna obeležja kreću u veoma sličnim opsezima, treba da centriramo podatke pre pokretanja PCA.
    5) Ukoliko imamo n-dimenzione podatke, ima smisla da pokrećemo PCA sa $k \leq n$, gde je k željeni broj dimenzija. Konkretno, pokretanje PCA sa $k = n$ je moguće ali nije od koristi, dok $k > n$ nema smisla.
    6) Treba da uklonimo visoko korelirana obeležja pre primene PCA.
    7) Recimo da iskoristimo PCA da projektujemo d-dimenzione tačke u j-dimenzioni prostor. Zatim, ponovo pokrenemo PCA da projektujemo te tačke iz j-dimenzionog prostora u k-dimenzioni prostor ($d > j > k$). Dobićemo isti rezultat kao da smo iskoristili PCA da direktno projektujemo d-dimenzione tačke u k-dimenzioni prostor.
    8) Recimo da dodamo 1 na kraj vektorske reprezentacije svake instance u skupu podataka. Ovo neće promeniti rezultate PCA (osim što će korisne glavne komponente imati 0 na kraju i imaćemo jednu dodatnu beskorisnu komponentu sa sopstvenom vrednošću 0).
    9) I PCA i LDA su linearne transformacije.

10) LDA je nadgledan metod, dok je PCA nenadgledan.

11) PCA maksimizuje varijansu u podacima, dok LDA maksimizuje separaciju između različitih klasa.

13. Koje od sledećih su preporučene primene za PCA?
    1) Vizuelizacija podataka: da uzmemo 2D podatke i pronađemo drugi način da ih plotujemo u 2D (koristimo $k = 2$).
    2) Kao zamena (ili alternativa) linearnoj regresiji: u dosta primena, PCA i linearna regresija daju slične rezultate.
    3) Kompresija podataka: pre obučavanja modela nadgledanog učenja, smanjimo dimenzionalnost ulaznih podataka kako bismo ubrzali učenje.
    4) Kompresija podataka: smanjimo dimenzionalnost podataka kako bi zauzimali manje prostora na disku/u memoriji.
14. Šta će se desiti ako su sopstvene vrednosti približno jednake?
    1) PCA će imati odlične performanse
    2) PCA će raditi loše (nećemo moći da odaberemo glavne komponente)
    3) Ne možemo reći.
15. Kako možemo evaluirati performanse algoritma za redukciju dimenzionalnosti?

    porediti rezultat sa i bez redukcije dimenzionalnosti

16. Šta od sledećih mogu da budu prve dve glavne komponente nakon primene PCA? 1) (0.5, 0.5, 0.5, 0.5) i (0.71, 0.71, 0, 0)
    2) (0.5, 0.5, 0.5, 0.5) i (0, 0, -0.71, -0.71)
    3) (0.5, 0.5, 0.5, 0.5) i (0.5, 0.5, -0.5, -0.5)
    4) (0.5, 0.5, 0.5, 0.5) i (-0.5, -0.5, 0.5, 0.5)
17. Šta je tačno kada imamo podatke projektovane u prostor niže dimenzionalnosti dobijen pomoću PCA?
    1) Nova obeležja su i dalje interpretabilna.
    2) Nova obeležja gube interoperabilnost
    3) Nova obeležja sigurno sadrže sve informacije iz originalnog skupa podataka
    4) Nova obeležja ne moraju da sadrže sve informacije iz originalnog skupa podataka.

Test 12 - Praktični saveti za primenu ML

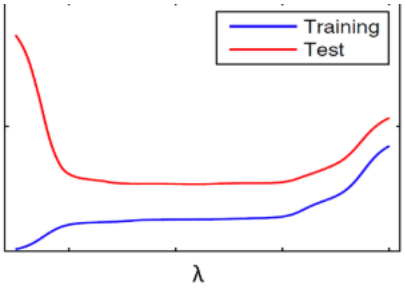
1. Navedite barem tri mere kvaliteta modela koje biste koristili u slučaju klasifikacije:
   - accuracy
   - F1
   - precision/recall

2. Navedite barem dve mere kvaliteta modela koje biste koristili u slučaju regresije:
   - rmse
   - r^2

3. Popunite tabelu (za definicije ne morate stavljati formule, u redu je da opišete smisao rečima)

Metrika	Definicija	Primer realne primene gde biste datu metriku upotrebili kao najbolju za evaluaciju modela
Preciznost	true positives/(true postivies+false positives)	sistem za filtriranje e-mailova koji detektuje spam poruke. Cilj je da se smanji broj lažno pozitivnih e-mailova
Odziv	true positives/ (true positives + false negatives)	Pretpostavimo da razvijate sistem za detekciju požara u šumama na osnovu satelitskih snimaka. U ovom scenariju, važno je detektovati što veći broj stvarnih požara kako bi se moglo brzo reagovati i sprečiti širenje.
F-mera	2*(precision*recall)/(precision)+recall	detetkcija raka
RMSE	mera koja kvantifikuje prosečnu razliku između stvarnih vrednosti i predviđenih vrednosti u odnosu na model, uzimajući u obzir kvadratne razlike i zatim izračunavajući kvadratni koren te vrednosti.	model za predviđanje cene kuća na osnovu različitih karakteristika kao što su kvadratura, broj soba, lokacija, itd.
R^2	mera koja predstavlja udeo varijacije zavisne promenljive koju objašnjava nezavisna promenljiva u odnosu na ukupnu varijaciju zavisne promenljive	prinosa useva na osnovu različitih faktora kao što su količina padavina, vrsta zemljišta, upotreba đubriva, temperatura, itd

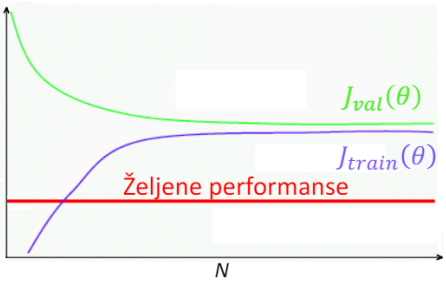
4. Grafik prikazuje trening i test grešku za model linearne regresije sa regularizacionim parametrom λ: $J(\theta) = \frac{1}{2N}\left(\sum_{i=1}^{N}\left(h_\theta\left(x^{(i)}\right) - y^{(i)}\right)^2 + \lambda\sum_{i=1}^{d}\theta_j^2\right)$. Označite za koju vrednost λ model pati od: (1) velikog sistematskog odstupanja (*bias*), (2) velike varijanse (*variance*).

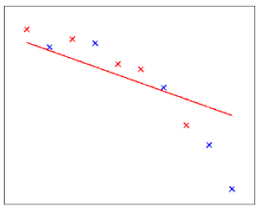


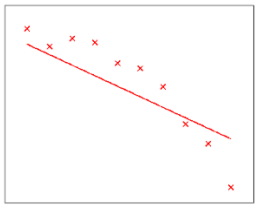
4.
levo je veliko varijansa desno je sistematsko odstupanje

5. Opišite kako dobijamo *learning curves* i kako ih koristimo za ML dijagnostiku (skicirajte primer za veliku varijansu i primer za veliko sistematsko odstupanje).
   - learning curves nam pomaze da vidimo da li model pati od velikog sistematskog odstupanja ili varijanse
   - iscrtavamo gresku treninga i validacije kao funkciju velicine trening skupa n, vestacki smanjujemo kolicinu dostupnih podataka za obucavanje i iscrtavamo ove greske da vidimo sta bi bilo da imamo manji trening skup

Veliko sistematsko odstupanje

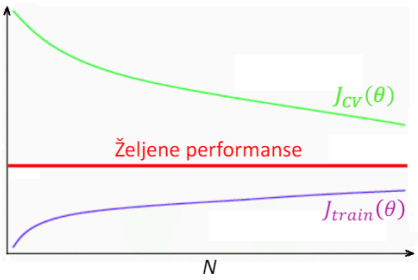


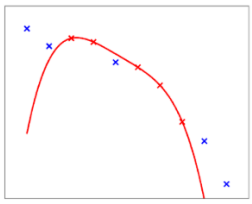


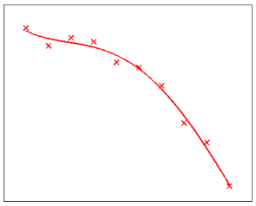


- Uočavamo da se trening greška brzo izravnava
- Greška na validacionom skupu bliska je grešci na trening skupu i obe su velike
- Kod modela koji ima veliko sistematsko odstupanje, dodavanje novih primera neće pomoći

Velika varijansa







- Uočavamo da trening greška još raste, a greška na validacionom skupu još opada
- Veliki raskorak greške na validacionom i trening skupu
- Kod modela koji ima veliku varijansu, dodavanje novih primera će verovatno pomoći

6. Projektni tim je izvršio selekciju važnih obeležja nad celim skupom podataka i značajno smanjio broj obeležja. Nakon toga, podelili su podatke u trening i test skup. Zatim su optimizovali više modela na trening skupu i evaluirali njihove performanse na test skupu. Kao performanse modela prijavljene su performanse najboljeg modela postignute nad test skupom. Da li je ova postavka korektna? Obrazložite.

valjda fali da prvo pokusaju sa jednostavnim modelom , takodje fali validacioni skup za podesavanje hiperparametara modela

7. Koje od navedenih strategija su adekvatne strategije za rešavanje problema velikog sistematskog odstupanja, a koje za rešavanje problema velike varijanse:

	Bias	Varijansa
Uvećanje fleksibilnosti modela (npr. dodavanje slojeva/neurona u neuronsku mrežu)	x	
Primena *feature engineering* (npr. izmena ili dodavanje obeležja prema uvidima proisteklim iz analize grešaka modela)	x	x
Selekcija obeležja da bi se smanjio broj obeležja		x
Early stopping (zaustaviti *gradient descent* ranije, zasnovano na grešci validacionog skupa)		x
Izmena modela (npr. izmena arhitekture neuronske mreže)	x	x
Dodavanje više trening podataka		x
Smanjenje kompleksnosti modela		x
Smanjenje šuma u trening skupu		x
Smanjenje ili uklanjanje regularizacije	x	
Dodavanje regularizacije		x

8. Šta označava pojam Okamova oštrica u kontekstu mašinskog učenja?
- imamo objasnjenje podataka, nastavljamo da orezujemo objasnjenje sve dok ne stignemo do minimuma koji je i dalje konzistentan sa podacim, i njega smatramo najboljim mogucim objasnjenjem
- najjednostavniji model koji odgovara podacima je najverodostnojinji
- sta znaci da je model jednostavan

1. KOMPLEKSNOST POJEDINACNE HIPOTEZE H
   - mere se odnose na pojedinacan objekad i kompleksnost je svojstvo samog objekta
   - MDL min description length - dati objekat pokusavamo da specificiramo sa najmanje moguce bitova
2. KOMPLESKONST SKUPA HIPOTEZA H
   - kompleksnost se izracunama za skup objekata
   - entropija
   - VC dimenzija - svojstvo skupa hipotez, posmatra skup hipoteza i predstavlja jedinstven broj koji oznacava raznolikost tog skupa hipoteza

9. Šta označava pojam *sampling bias*?
moramo obezbedidi da podaci budu reprezentativni u odnosu na ono sto zelimo da pokazemo

10. Navedite primer *sampling bias*-a.
izbor predsednika usa 1948 kad su zvali ljude da pitaju za koga su glasali pa su izvestili pogresnog pobednika jer je dobijeni rezultat bio posledica sistematske greske u uzorkovanju jer su samo bogati imali telefon

11. Kako rešavamo problem *sampling bias*-a?
poklapanje distribucija - instance koriscenje za obucavanje su odabrane iz iste distribucije kao i instance koje koristimo za testiranje.

12. Šta označava pojam *data snooping*?
ako je skup podataka imao uticaja na bilo koji korak ucenja onda je mogucnost ovog skupa da proceni ishod ucenja kompromitovana

13. Kako rešavamo problem *data snooping*-a?
- izbegavanje
  - disciplina - stavite test podatke u sef i nemojte ga otvarati dok nemate finalnu hipotezu
- uracunajte i efekat data snoopinga u performanse, tj kolika je kontaminacija pokdataka

Test 13 - Polu-nadgledano učenje

1. Šta je cilj i motivacija za primenu polu-nadgledanog učenja?

   Cilj - obuciti klasifikator f koji je bolji od klasifikatora obucenog samo na anotiranim podacim

   Motivacija - u nadgledanom ucenju trening skup se sastoji iz anotiranih primera, da bi rezultujuci predikcioni modeli bili kvalitetni neophodno je prikupiti velik i raznovrsan skup sto zahteva mnogo vremena ekspreata sto je dugotrajno i skupo pa cemo pokuasti da u proces obucavanja ukljucimo neanotirane podatke

2. Navedite primer problema gde bi polu-nadgledano učenje bilo korisno (obrazložite zašto).

   Kod klasifikacije tesktsa bismo mogli da koristimo polu nadgledano ucenje jer prikupljanje podataka za neku predikciju jer bismo mogli da koristimo delimicno poluanotirane podatke sto bi ubrzalo vreme celokupnog procesa,

3. Kako biste postavili eksperiment iz polu-nadgledanog učenja?

4. Koja je razlika između induktivnog i transduktivnog obučavanja? Navedite primere jedne i druge kategorije.

   induktivno ucenje - obucavamo funkciju f koju cemo primeniti na test skup i koristimo f da odredimo labele neanotiranih primera

   transduktivno - ne ucimo eksplicitnu funkciju nego nas samo zanima da dobijemo labele za neanotirane podatke tj neanotirani su nam kao test podaci koji su dostupni tokom obucavanja

5. Koja je razlika akivnog obučavanja i polu-nedgledanog obučavanja?

   Kod aktivnog ucenja selektuju se najbolji neobelezeni reprezentativni primeri za selektovanje od strane eksperta, dok polunagledano obelezava neobelezene podatke na osnovu obelezenih podataka bez dodatne ljudske interakcije

6. Kako nam neanotirani podaci mogu pomoći u obučavanju? Šta je nedostatak ovih metoda?

   Pomazu nam da steknemo bolji osecaj za P(x) - omoguciti nam da odredimo distribuciju preciznije, dobijamo degradaciju performansi ukoliko navedene pretpostavke nisu tacne

7. Navedite primer jedne pretpostavke koje uvodi neki metod polu-nadgledanog učenja. Navedite slučaj kada je ta pretpostavka narušena.

   14.

8. Odaberite i opišite jedan algoritam polu-nadgledanog obučavanja. Navedite njegove prednosti i mane.

   14.

9. Šta su Generativni modeli? Koje generativne modele smo učili?

   Generativni modeli su vrsta modela u području strojnog učenja koji imaju zadatak generiranja novih primjera podataka koji su slični onima koji su korišteni za njihovo učenje. Ovi modeli se suprotstavljaju diskriminativnim modelima, koji se fokusiraju na razlikovanje između različitih klasa ili kategorija podataka.

   Primer su GMM NB HMM

10. Pojasnite kako se generativni modeli mogu koristiti za polu-nadgledano učenje. Koje pretpostavke se uvode? Koje su prednosti i mane ovog postupka?

- Uvedena pretpostavka:
  - Generativni model $P(x, y|\theta)$

- Prednosti:
  - Jasno, dobro proučeno probabilističko okruženje
  - Može da bude izuzentno efektivno, ukoliko je pretpostavljeni model blizak stvarnom modelu

- Mane:
  - Često je teško verifikovati da li pretpostavljeni model odgovara podacima
  - A ukoliko ne odgovara, neanotirani podaci mogu degradirati performanse modela
  - Parametri modela se često procenjuju primenom EM metode koja je podložna upadanju u lokalni optimum

11. Šta je metoda očekivanje-maksimizacija *(Expectation-Maximization)*? Kako se ona može primeniti u kontekstu polu-nadgledanog učenja?

- Parametri generativnog modela se mogu estimirati metodom očekivanje-maksimizacija (*Expectation-Maximization*, *EM*)
- EM metoda je primenljiva kada se u podacima javljaju nedostajuće vrednosti
- U kontekstu polu-nadgledanog obučavanja, klasna obeležja tretiramo kao nedostajuće vrednosti

- Iterativno ponavljati ova dva koraka (do konvergencije):
  1. Nadgledanim obučavanjem (skup *L*) odrediti parametre generativnog modela. Iskoristiti model da se neanotiranim instancama (skup *U*) dodele klasna obeležja
  2. Re-evaluirati parametre modela koristeći sve instance (uključujući i one anotirane u koraku 1)

12. Objasnite postupak klasterovati-i-anotirati. Koje pretpostavke se uvode? Koje su prednosti i mane ovog postupka?

- Umesto probabilističkih generativnih modela, možemo koristiti bilo koji algoritam za klasterovanje:
  - Primeniti model za klasterovanje na *L* i *U*
  - Anotirati sve neanotirane instance unutar klastera većinskim glasanjem anotiranih instanci u klasteru
  - Trenirati nadgledani model nad svim instancama

- Pretpostavka:
  - Ako dve tačke pripadaju istom klasteru, onda verovatno pripadaju istoj klasi
- Prednost:
  - jednostavan metod, poznati algoritmi
- Mana:
  - Može biti težak za analizu
  - Degradira performanse ukoliko pretpostavka nije tačna

13. Objasnite ideju modela zasnovanih na grafovima. Koje pretpostavke se uvode?

- Generišemo graf:
  - Čvorovi: instance (anotirane i neanotirane)
  - Grane: reflektuju sličnost instanci
    - *K*-NN graf (bez težina)
    - Potpuno povezan graf gde se težine smanjuju sa udaljenošću (npr. Euklidskom)

- Ove metode se obično baziraju na pretpostavci o „glatkoći“ labela u grafu
  - Bliski čvorovi (povezani granom velike težine) trebaju da imaju slične labele
  - Ova ideja se naziva i *Graph-based regularization*

14. Objasnite ideju samo-obučavanja. Koja pretpostavka se uvodi? Koje su prednosti ovog pristupa? Koji je nedostatak ovog pristupa?

Klasifikator koristi sopstvene predikcije da iterativno obucava samog sebe. Uvodi se pretpostavka da su sopstvene predikcije visoke pouzdanosti tacne

Prednosti su najjednostavniji moteod polunadgledanog ucenja, moze se koristiti bilo koji nadgledani model bilo koje kompleksnosti i cesto radi dobro u praksi, a mana je da rane greske u klasifikaciji mogu da pojacavaju same sebe

15. Objasnite ideju ko-treninga: kada se može primeniti, kada će biti uspešan, šta je nedostatak ovog pristupa? ne znam sta se desava