Otkrivanje šablona samostalnog učenja koji dovode do uspeha na ispitu

Teodor Sakal Franciškoviću, Jelena Slivka
Softversko Inženjerstvo i Informacione Tehnologije, Univerzitet u Novom Sadu, Fakultet tehničkih nauka
teodor.sakal_franciskovic@uns.ac.rs, slivkaje@uns.ac.rs

I. Problem

Tokom tradicionalnih predavanja predavač izlaže gradivo pred grupom učenika. Učenici poseduju različito predznanje i afektivno stanje u vreme predavanja. Međutim, predavač izlaže gradivo svima na isti način, što rezultuje slabim zadržavanjem znanja za deo publike [1] [2].

Obrnuta učionica (*flipped classroom*) može da unapredi ishode učenja u odnosu na tradicionalna predavanja. U obrnutoj učionici učenici samostalno rešavaju zadatke koji ih pripremaju za predavanja [3]. Uspeh metoda zavisi od učeničkog blagovremenog, redovnog i fokusiranog rada na zadacima [4]. Međutim, učenicima često predstavlja izazov da održavaju redovan šablon učenja, pogotovo ako se učenje odvija *online* [5]. Neredovno učenje rezultuje lošim ishodima učenja, poput kratkotrajnog zadržavanje znanja i ne razvijanja dubokog razumevanja [6].

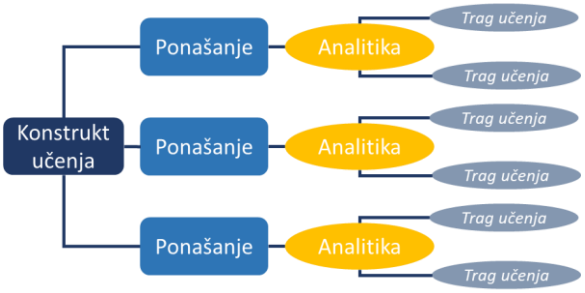
Ovaj rad istražuje uticaj redovnosti pripreme za predavanja u obrnutoj učionici na broj bodova na završnom ispitu. Rezultati daju uvid u uspešne i neuspešne strategije učenja. Uvidi su korisni učenicima u organizaciji njihovog rada. Instruktorima ovakvi uvidi omogućavaju da identifikuju učenike koji primenjuju neuspešne strategije i sprovedu akcije za poboljšanje uspeha tih studenata.

II. Teorijske osnove

Opisani problem rešavamo primenom analitike učenja. Analitika učenja (*learning analytics*) je proces prikupljanja i analize podataka o učenicima i kontekstu učenja sa ciljem njihovog unapređenja [7]. Na primer, analitika učenja se može primeniti u cilju identifikovanja i uklanjanja miskoncepcija i pogrešno usmerenog truda [8].

Kontekst učenja obuhvata interne i eksterne uslove u kojima se učenje odvija. Primeri internih uslova su motivacija i predznanje učenika, a primeri eksternih uslova su primena modela obrnute učionice i nametnuti rokovi. Specifikacija konteksta učenja je ključna za interpretaciju rezultata dobijenih analitikom učenja jer može da objasni razlike u kontradiktornim rezultatima različitih studija [8].

Slika 2 ilustruje glavne koncepte modela analitike učenja [9]. *Konstrukt učenja* izražava učenička ponašanja, stavove, procese učenja ili iskustvo. Na primer, konstrukt učenja koji razmatramo u ovom radu je redovnost učenikovog angažovanja. Konstrukt učenja nije direktno merljiv, ali se manifestuje kroz učenikovo *ponašanje* u okruženju za učenje. Za prethodni primer, redovnost učenikovog angažovanja možemo proceniti iz ponašanja poput održavanja konzistentne dužine sesija učenja na dnevnom ili nedeljnom nivou [10][11]. Ponašanja procenjujemo pomoću *analitika* – na primer, za računanje konzistentnosti dužine sesija nam je potrebna analitika koja izražava dužinu sesije. Analitike računamo iz *tragova učenja* (*learning traces*). Na primer, ako učenik interaguje sa *online* platformom za učenje, kao tragove učenja možemo zabeležiti početak i kraj sesije. Nakon mapiranja konstrukta na tragove učenja, možemo ga proceniti iz zabeleženih podataka.



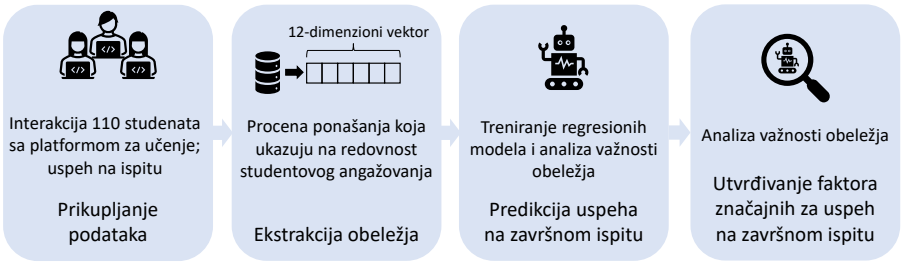
Slika 2 Mapiranje konstrukta, prilagođeno iz [9]

III. Rešenje

Slika 1 prikazuje postupak kojim smo analizirali kako redovnost angažovanja na pripremnim aktivnostima za čas utiče na uspeh učenika na završnom ispitu.

A. Prikupljanje podataka

Naš kontekst učenja je bio kurs softverskog inženjerstva koji je dizajniran po modelu obrnute učionice. Teorijske osnove kursa su izlagane na *online* platformi za učenje i služile su kao priprema za predavanja. Na kraju kursa, studenti su polagali završni teorijski ispit na papiru. Ciljno obeležje za predikciju je broj bodova koje je student ostvario na završnom teorijskom ispitu (od 0 do 20 poena).



Slika 1 Postupak utvrđivanja veze redovnosti angažovanja na pripremnim aktivnostima za čas sa uspehom studenta na završnom ispitu

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

Od 184 studenta upisanih na kurs, u analizu smo uključili samo one studente koji su polagali teorijski ispit (110 studenata). Ovi studenti nisu imali prethodno iskustvo sa modelom obrnute učionice.

Materijali na *online* platformi za učenje su bili organizovani u segmente. Za svaki segment je student prelazio gradivo i rešavao sekvencu zadataka. Ukoliko bi studentov odgovor na zadatak bio pogrešan, platforma bi mu ponudila smernicu (*hint*). U slučaju više neuspešnih pokušaja, platforma bi studenta prebacila na sledeći zadatak. Student bi ponovo dobio nerešene zadatke nakon što je pokušao da uradi sve zadatke. Smatralo se da je student kompletirao segment kada bi prešao određeni prag tačnosti izračunat nad svim zadacima. Studentima su bili zadati rokovi za kompletiranje segmenata. Platforma za učenje je beležila tragove učenja tokom ovog procesa.

B. Ekstrakcija obeležja

Tabela 1 prikazuje obeležja korišćena za predikciju uspeha studenta na teorijskom ispitu. Ponašanjima koja ukazuju na redovnost studentovog angažovanja predloženim u [10] i [11] smo pridodali ponašanja specifična za naš kontekst učenja.

C. Utvrđivanje faktora značajnih za uspeh na ispitu

Primenom nasumičnog stratifikovanog uzorkovanja (*stratified sampling*) smo podelili podatke na trening (75%) i test (25%) skup.

Na trening skupu smo primenili eksplorativnu analizu podataka (*exploratory data analysis*). Od 82 instance u trening skupu, uklonili smo 12 za koje smo utvrdili da predstavljaju *outlier*-e (primenom *Interquartile Range* metode). Uklonili smo obeležje *Entropija_dnevnih_sesija* koje je bilo u velikoj korelaciji sa drugim obeležjima. Logaritmovanjem i korenovanjem smo transformisali vrednosti obeležja da bi njihove distribucije imale raspodelu približnu normalnoj. Konačno, normalizovali smo vrednosti obeležja z-normalizacijom.

Trenirali smo sledeće regresione modele:

- linearna regresija (*linear regression*)
- *elastic net* regresija
- *Huber* regresija
- stabla odluke (*decision tree*)
- metod potpornih vektora (*support vector machine*)
- *K*-najbližih suseda (*K-nearest neighbors*)
- *gradient boosting*
- metod nasumične šume (*Random Forest, RF*)

Hiper-parametre modela smo optimizovali primenom petostruke unakrsne validacije nad trening skupom podataka, primenom *Grid Search* optimizacione strategije. Kao ciljnu metriku za optimizaciju hiper-parametara smo koristili koeficijent determinacije (R^2).

Postupkom optimizacije hiper-parametara smo utvrdili da najbolje performanse postiže RF. Ovaj model smo evaluirali nad test skupom podataka koristeći R^2 i RMSE (*Root Mean Squared Error*) metrike. Kako bismo utvrdili faktore koji najviše utiču na prediktivnu moć modela, ispitali smo uticaj obeležja na *Gini* čistoću RF modela.

IV. Rezultati i diskusija

Trenirani RF model je na test skupu postigao R^2 od 0.1 i 3.73 RMSE (relativna greška od 18.6%). Iako je dobijena vrednost R^2 niska, RMSE pokazuje da model može dosta precizno da predvidi bodove studenta na završnom ispitu na osnovu ponašanja koja ukazuju na redovnost angažovanja.

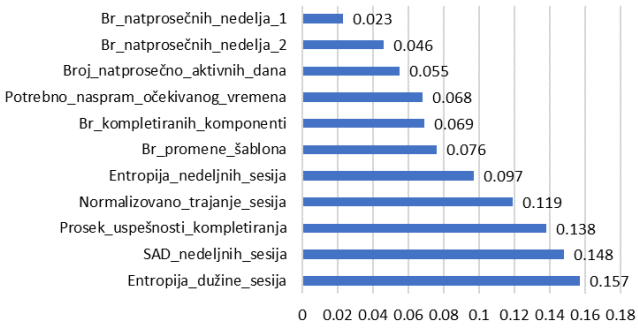
Performanse modela su uporedive sa performansama prikazanim u literaturi. Jovanović i drugi su postigli R^2 u opsegu [0.12, 0.24] u radu [10] i R^2 u opsegu [0.03, 0.05] u radu [11]. Mogući razlog za razlike u rezultatima je razlika u kontekstima učenja. Određena ponašanja koja ukazuju na redovnost angažovanja predložena u [10] i [11] nisu bila relevantna za naš kontekst. Takođe, radovi [10] i [11] su razmatrali kurseve iz različitih disciplina (računarsko inženjerstvo i medicina) i studente različitih godina studija.

Slika 3 prikazuje značaj ponašanja koja ukazuju na redovnost angažovanja studenta za prediktivne performanse

Tabela 1 Obeležja korišćena za predikciju uspeha na teorijskom ispitu (ponašanja koja ukazuju na redovnost angažmana)

Obeležje	**Opis**	**Izvor**
Entropija_nedeljnih_sesija	Entropija dužine nedeljnih sesija	[10]
Entropija_dnevnih_sesija	Entropija dužine dnevnih sesija	[10]
Br_natprosečnih_nedelja_1	Broj nedelja sa natprosečnim brojem sesija u prvoj polovini semestra	[10]
Br_natprosečnih_nedelja_2	Broj nedelja sa natprosečnim brojem sesija u drugoj polovini semestra	[10]
SAD_nedeljnih_sesija	Srednja apolutna devijacija dužine nedeljnih sesija	[10]
Br_promene_šablona	Za svaku nedelju se izračuna vektor verovatnoća da student učiti određenog dana (broj sesija u danu podeljen brojem sesija u nedelji). Promena šablona učenja u dve uzastopne nedelje se računa kao srednja kvadratna distanca njihovih vektora. Za svakog studenta se računa broj nedelja gde je promena šablona učenja bila značajna (prešla zadati prag).	[10]
Broj_natprosečno_aktivnih_dana	Broj nedelja u kojima je broj aktivnih dana iznad zadatog praga (vrednost trećeg kvartila)	[10]
Normalizovano_trajanje_sesija	Normalizovano ukupno trajanje sesija	[11]
Entropija_dužine_sesija	Entropija dužine sesija	[11]
Potrebno_naspram_očekivanog_vremena	Odnos potrebnog i očekivanog vremena za kompletiranje segmenta. Računa se prosek ovog odnosa za datog studenta.	Ova studija
Br_kompletiranih_komponenti	Broj kompletiranih segmenata	Ova studija
Prosek_uspešnosti_kompletiranja	Broj neuspešnih pokušaja rada na segmentu pre njegovog kompletiranja. Računa se prosečna vrednost za datog studenta.	Ova studija

modela. Vidimo da se model pri predikciji najviše oslanja na ponašanja koja izražavaju uniformnost dužine sesija, što je poravnato sa zaključcima iz [10] i [11]. Možemo zaključiti da je za uspeh na ispitu potreban redovan rad. Takođe možemo zaključiti da studenti koji održavaju konzistentne šablone učenja postižu veći uspeh na ispitu.



Slika 3 Značaj ponašanja koja ukazuju na redovnost angažovanja za predikciju

Ova studija ima nekoliko ograničenja koja su mogla uticati na izvedene zaključke. Merili smo analitike iz podataka prikupljenih pomoću *online* platforme za učenje. Postoji rizik da ova merenja nisu reprezentacija konstrukta učenja koji pokušavamo da procenimo. Na primer, smatra se da je sesija pauzirana ukoliko student nije aktivan duže od tri minuta. Međutim, moguće je da student koristi vreme da razmisli o zadatku ili zapiše beleške. Slično, merili smo koliko je segmenata student kompletirao. Međutim, varanje nije isključeno – studenti su mogli rešiti zadatke uz pomoć drugih kolega.

Naši zaključci mogu biti pogrešni i ukoliko smo pogrešno interpretirali ponašanja koja ukazuju na redovnost angažmana predložena u [10] i [11]. Takođe, izveli smo zaključke na osnovu jedne podele podataka na trening i test skup koja je mogla biti pristrasna.

Studiju smo izveli koristeći podatke studenata koji su pohađali kurs softverskog inženjerstva na trećoj godini osnovnih akademskih studija. Studenti koji pohađaju kurs su bili slični po starosti i iskustvu i nisu imali prethodnog iskustva sa modelom obrnute učionice. Ne možemo sa sigurnošću tvrditi da naši zaključci važe i za druge domene učenja, studente sa više iskustva sa modelom obrnute učionice ili studente koji pohađaju drugačije organizovane kurseve.

LITERATURA

[1] Van Dijk, L., Van Der Berg, G.C. and Van Keulen, H., 2001. Interactive lectures in engineering education. *European Journal of Engineering Education*, *26*(1), pp.15-28.

[2] Aleven, V., McLaughlin, E.A., Glenn, R.A. and Koedinger, K.R., 2016. Instruction based on adaptive learning technologies. *Handbook of research on learning and instruction*, *2*, pp.522-560.

[3] Lage, M.J., Platt, G.J. and Treglia, M., 2000. Inverting the classroom: A gateway to creating an inclusive learning environment. *The journal of economic education*, *31*(1), pp.30-43.

[4] Rahman, A.A., Aris, B., Rosli, M.S., Mohamed, H., Abdullah, Z. and Mohd Zaid, N., 2015. Significance of preparedness in flipped classroom. *Advanced Science Letters*, *21*(10), pp.3388-3390.

[5] Panzarasa, P., Kujawski, B., Hammond, E.J. and Michael Roberts, C., 2016. Temporal patterns and dynamics of e-learning usage in medical education. *Educational Technology Research and Development*, *64*, pp.13-35.

[6] Kornell, N., 2009. Optimising learning using flashcards: Spacing is more effective than cramming. *Applied Cognitive Psychology: The Official Journal of the Society for Applied Research in Memory and Cognition*, *23*(9), pp.1297-1317.

[7] Long, P. and Siemens, G., 2011. What is learning analytics. In *Proceedings of the 1st International Conference Learning Analytics and Knowledge, LAK* (Vol. 11).

[8] Mangaroska, K. and Giannakos, M., 2018. Learning analytics for learning design: A systematic literature review of analytics-driven design to enhance learning. *IEEE Transactions on Learning Technologies*, *12*(4), pp.516-534.

[9] Lang, C., Siemens, G., Wise, A. and Gasevic, D. eds., 2017. *Handbook of learning analytics* (p. 23). New York: SOLAR, Society for Learning Analytics and Research.

[10] Jovanovic, J., Mirriahi, N., Gašević, D., Dawson, S. and Pardo, A., 2019. Predictive power of regularity of pre-class activities in a flipped classroom. *Computers & Education*, *134*, pp.156-168.

[11] Jovanović, J., Saqr, M., Joksimović, S., & Gašević, D. (2021). Students matter the most in learning analytics: The effects of internal and instructional conditions in predicting academic success. *Computers & Education*, *172*, 104251.